



**UNIVERSIDAD  
SERGIO ARBOLEDA**

# **MODELO PREDICTIVO DE SERIES DE TIEMPO PARA LA INCIDENCIA DEL VIH EN MEDELLÍN**

**NATHALIA ANDREA CANO ORTEGA**

**UNIVERSIDAD SERGIO ARBOLEDA  
ESCUELA DE CIENCIAS EXACTAS E INGENIERÍA**

**BOGOTÁ D.C.**

**2025**

# MODELO PREDICTIVO DE SERIES DE TIEMPO PARA LA INCIDENCIA DEL VIH EN MEDELLÍN

NATHALIA ANDREA CANO ORTEGA

DOCUMENTO FINAL DE MAESTRÍA

Asesor:  
Juan Pablo Ospina López PhD

UNIVERSIDAD SERGIO ARBOLEDA  
ESCUELA DE CIENCIAS EXACTAS E INGENIERÍA  
MAESTRÍA EN INTELIGENCIA ARTIFICIAL

BOGOTÁ D.C.

2025

---

Nota de aceptación:

---

---

---

---

---

---

---

Firma del presidente del jurado

---

Firma del jurado

---

Firma del jurado

# Agradecimientos

---

En primer lugar, doy gracias a Dios, por ser mi guía y fortaleza en cada etapa de este proceso. Por permitirme alcanzar esta meta, llenarme de sabiduría y perseverancia. "Pero los que esperan a Jehová tendrán nuevas fuerzas; levantarán alas como las águilas; correrán, y no se cansarán; caminarán, y no se fatigarán." (Isaías 40:31). Sin su amor y dirección, este logro no habría sido posible.

A mi familia, gracias por ser mi pilar fundamental, por su amor incondicional, por apoyarme en los momentos de dificultad y celebrar cada pequeño avance. Sus palabras de aliento y sacrificios han sido el motor que me impulsó a seguir adelante.

A mi asesor de tesis, por su paciencia, dedicación y valiosas enseñanzas. Su orientación experta y constante motivación fueron clave para culminar este trabajo. Agradezco su tiempo, sus consejos y la confianza que depositó en mí.

A todos aquellos que, de una u otra forma, contribuyeron a este logro, gracias por acompañarme en este camino. Cada palabra de apoyo, cada gesto de solidaridad hizo la diferencia.

# Resumen

---

El VIH en Medellín, Colombia, representa un desafío crítico de salud pública, con tasas crecientes de incidencia y disparidades en poblaciones vulnerables. Este estudio compara modelos tradicionales (Holt-Winters, SARIMA), machine learning (Random Forest, XGBoost) y deep learning (LSTM, Transformers) para predecir casos de VIH, utilizando datos mensuales (2012-2022) evaluados con métricas como RMSE, MAE, MAPE y  $R^2$ . Los resultados destacan que Holt-Winters logra el mejor equilibrio entre precisión, interpretabilidad y estabilidad, capturando patrones estacionales, mientras que los modelos avanzados, aunque precisos, presentan limitaciones en capturar las tendencias de las semanas epidemiológicas. La investigación subraya la utilidad de Holt-Winters como herramienta práctica para la planificación en salud pública, integrando análisis técnicos con perspectivas sociales y éticas en la prevención del VIH.

**Palabras Clave:** VIH/SIDA, Modelos predictivos, Series de tiempo, Salud pública, Medellín.

## Abstract

HIV in Medellín, Colombia, represents a critical public health challenge, with rising incidence rates and disparities among vulnerable populations. This study compares traditional models (Holt-Winters, SARIMA), machine learning (Random Forest, XGBoost), and deep learning (LSTM, Transformers) to predict HIV cases using monthly data (2012-2022), evaluated with metrics such as RMSE, MAE, MAPE, and  $R^2$ . Results highlight that Holt-Winters achieves the best balance between accuracy, interpretability, and stability while capturing seasonal patterns, whereas advanced models, though precise, exhibit limitations in capturing epidemiological week trends. The research underscores the utility of Holt-Winters as a practical tool for public health planning, integrating technical analyses with social and ethical perspectives in HIV prevention.

**Keywords:** HIV/AIDS, Predictive models, Time series, Public health, Medellín.

# Contenido

---

|                                                                                                      |           |
|------------------------------------------------------------------------------------------------------|-----------|
| <b>LISTA DE FIGURAS</b>                                                                              | <b>8</b>  |
| <b>LISTA DE TABLAS</b>                                                                               | <b>10</b> |
| <b>GLOSARIO</b>                                                                                      | <b>11</b> |
| <b>INTRODUCCIÓN</b>                                                                                  | <b>13</b> |
| <b>DESCRIPCIÓN DEL PROBLEMA</b>                                                                      | <b>15</b> |
| <b>OBJETIVOS</b>                                                                                     | <b>20</b> |
| 1. Objetivo General                                                                                  | 20        |
| 2. Objetivos Específicos                                                                             | 20        |
| 3. Hipótesis                                                                                         | 20        |
| <b>ESTADO DEL ARTE</b>                                                                               | <b>21</b> |
| <b>4.1. Evolución Histórica de la Epidemia del VIH</b>                                               | <b>21</b> |
| 4.1.1. Los orígenes (1980-1990): Identificación y estigma                                            | 21        |
| 4.1.2. La revolución antirretroviral (1990-2000): De la fatalidad a la condición crónica             | 22        |
| 4.1.3. Prevención combinada (2000-2010): Enfoques multidimensionales                                 | 22        |
| 4.1.4. Era de la IA (2010-2020): Modelos predictivos y desafíos éticos                               | 23        |
| <b>4.2. Modelos Predictivos en la Epidemiología del VIH: Avances, limitaciones y oportunidades</b>   | <b>23</b> |
| <b>4.3. Contexto Local: La Epidemia del VIH en Medellín y sus desafíos únicos</b>                    | <b>24</b> |
| <b>4.4. Inversión pública en salud y políticas de prevención en Medellín: una revisión histórica</b> | <b>27</b> |
| <b>4.5. Discusión: Hacia una respuesta integral con enfoque humano y tecnológico</b>                 | <b>28</b> |
| <b>4.6. Marco Legal y Ético: Fundamentos para una investigación responsable</b>                      | <b>28</b> |

|                                                              |           |
|--------------------------------------------------------------|-----------|
| <b>JUSTIFICACIÓN</b>                                         | <b>30</b> |
| <b>ALCANCES Y LIMITACIONES</b>                               | <b>31</b> |
| 6.1 Alcance                                                  | 31        |
| 6.2 Limitaciones                                             | 31        |
| <b>METODOLOGÍA Y DESARROLLO</b>                              | <b>32</b> |
| 7.1. Fase de entendimiento de la situación                   | 32        |
| 7.1.1 Contextualización del problema                         | 32        |
| 7.1.2. Identificación del problema                           | 33        |
| 7.2. Fase Entendimiento de los Datos                         | 35        |
| 7.2.1. Recopilación de Datos                                 | 35        |
| 7.2.2. Limpieza del Dataset                                  | 35        |
| 7.2.3. Análisis Descriptivo                                  | 36        |
| 7.2.4. Análisis Exploratorio                                 | 38        |
| 7.2.5 Análisis por Variables                                 | 43        |
| 7.2.6. Análisis Temporal                                     | 49        |
| <b>RESULTADOS</b>                                            | <b>55</b> |
| 8.1. Resultados de Modelos Tradicionales de Series de Tiempo | 55        |
| 8.2. Resultados de Modelos de Machine Learning               | 59        |
| 8.3. Resultados de Modelos de Deep Learning                  | 61        |
| 8.4. Modelos Híbridos                                        | 62        |
| 8.5. Comparativa General y Selección del Modelo Óptimo       | 64        |
| 8.6. Selección del Modelo Óptimo                             | 73        |
| <b>RECOMENDACIONES DE IMPLEMENTACIÓN</b>                     | <b>76</b> |
| <b>CONCLUSIÓN</b>                                            | <b>78</b> |
| <b>REFERENCIAS</b>                                           | <b>79</b> |

# Lista de Figuras

---

|                                                                                                          |    |
|----------------------------------------------------------------------------------------------------------|----|
| Figura 4.1: Casos de VIH por Comuna.....                                                                 | 25 |
| Figura 7.1: Línea del tiempo evolución del VIH.....                                                      | 33 |
| Figura 7.2: Evolución Mensual de Casos de VIH (2012-2022) .....                                          | 38 |
| Figura 7.3: Patrón Estacional de Casos de VIH (Promedio Mensual por Año) .....                           | 40 |
| Figura 7.4: Distribución de casos por mes (todos los años combinados) .....                              | 41 |
| Figura 7.5: Crecimiento interanual de Casos de VIH (2012-2022) .....                                     | 42 |
| Figura 7.6: Evolución anual de casos de VIH por sexo.....                                                | 43 |
| Figura 7.7: Distribución de los casos por sexo.....                                                      | 44 |
| Figura 7.8: Distribución y evolución de los casos por grupo de edad y sexo.....                          | 45 |
| Figura 7.9: Distribución de casos por nacionalidad y por sexo.....                                       | 46 |
| Figura 7.10: Distribución de casos de VIH por estrato socioeconómico.....                                | 47 |
| Figura 7.11: Evolución temporal de casos de VIH por estrato.....                                         | 48 |
| Figura 7.12: Descomposición de la serie temporal de casos de VIH.....                                    | 49 |
| Figura 7.13: Análisis de Componentes con media móvil.....                                                | 50 |
| Figura 7.14: Distribución de casos semanales con umbrales de anomalía.....                               | 52 |
| Figura 7.15: Autocorrelación de casos semanales.....                                                     | 53 |
| Figura 7.16: Evolución de Población y Tasa de Incidencia de VIH .....                                    | 54 |
| Figura 8.1: Resultados del RMSE y MAE para los modelos estadísticos clásicos.....                        | 56 |
| Figura 8.2: Evolución de Casos VIH (2022-2023) con predicción de los modelos estadísticos clásicos ..... | 58 |
| Figura 8.3: Resultados del RMSE y MAE para los modelos de Machine Learning.....                          | 59 |
| Figura 8.4: Evolución de Casos VIH (2022-2023) con predicción para los modelos de ML.....                | 61 |
| Figura 8.6: Evolución de Casos VIH (2022-2023) con predicción para los modelos de DL.....                | 62 |
| Figura 8.7: Resultados del RMSE y MAE para el modelo híbrido.....                                        | 63 |



|                                                                                            |    |
|--------------------------------------------------------------------------------------------|----|
| Figura 8.8: Evolución de Casos VIH (2022-2023) con predicción para el modelo híbrido ..... | 63 |
| Figura 8.9: Comparación de métricas de error por modelo (validación cruzada) .....         | 65 |
| Figura 8.10: Predicción de casos de VIH Modelo Holt-Winters.....                           | 67 |
| Figura 8.11: Diagrama de Flujo del Modelo Implementado Holt-Winters.....                   | 68 |
| Figura 8.12: Predicción de casos de VIH Modelo Random Forest.....                          | 69 |
| Figura 8.13: Diagrama de Flujo del Modelo Implementado Random Forest.....                  | 70 |
| Figura 8.14: Predicción de casos de VIH Modelo XGBoost.....                                | 70 |
| Figura 8.15: Diagrama de Flujo del Modelo Implementado XGBoost .....                       | 71 |
| Figura 8.16: ACF de Residuos del modelo XGBoost.....                                       | 72 |
| Figura 8.17: ACF de Residuos del modelo Holt-Winters.....                                  | 72 |
| Figura 8.18: ACF de Residuos del modelo Random Forest .....                                | 72 |

# Lista de Tablas

---

|                                                                                      |    |
|--------------------------------------------------------------------------------------|----|
| Tabla 2.1: Matriz DOFA Problemática del VIH en la ciudad de Medellín.....            | 18 |
| Tabla 7.1: Comparación de la Serie original vs. Serie suavizada.....                 | 51 |
| Tabla 8.1: Tabla comparativa de resultados de los modelos estadísticos clásicos..... | 55 |
| Tabla 8.2: Tabla comparativa de resultados de los modelos de Machine Learning.....   | 59 |
| Tabla 8.3: Tabla comparativa de resultados de los modelos de Deep Learning.....      | 61 |
| Tabla 8.4: Tabla comparativa de resultados del modelo híbrido.....                   | 62 |
| Tabla 8.5: Tabla comparativa de validación cruzada de los modelos evaluados.....     | 64 |

# Glosario

---

- 90-90-90 (95-95-95): Metas globales para diagnóstico, tratamiento y supresión viral del VIH.
- AIC (Criterio de Información de Akaike): Medida de calidad relativa de modelos estadísticos que penaliza la complejidad.
- Análisis Exploratorio de Datos (EDA): Proceso de investigar conjuntos de datos mediante estadísticas descriptivas y visualizaciones.
- ARIMA (AutoRegressive Integrated Moving Average): Modelo estadístico para series temporales que combina componentes autoregresivos, diferenciación y medias móviles.
- Attention Mechanisms: Componente de redes neuronales que asigna importancia diferencial a inputs.
- Autocorrelación (ACF): Correlación de una serie consigo misma en diferentes intervalos de tiempo.
- BIC (Criterio de Información Bayesiano): Similar al AIC, pero con mayor penalización por parámetros adicionales.
- Bootstrap Aggregating (Bagging): Técnica de ensamble para reducir varianza en predicciones.
- Carga Viral Comunitaria: Nivel de virus VIH en una población específica.
- Cascada de Cuidado del VIH: Continuo desde diagnóstico hasta supresión viral efectiva.
- Correlación Cruzada: Medida de similitud entre dos series temporales diferentes.
- Cross-validation (Validación Cruzada): Técnica para evaluar modelos dividiendo datos en subconjuntos de entrenamiento y validación.
- Determinantes Sociales de Salud: Factores como acceso a servicios, educación o condiciones laborales que afectan la salud.
- Dispersión Geográfica: Distribución espacial de casos (analizada con índices como Moran).
- Early Stopping: Método para detener entrenamiento de modelos y evitar sobreajuste.
- Embeddings: Representación vectorial de variables categóricas para modelos de ML.
- Epidemiología Social: Estudio de cómo los determinantes sociales afectan la salud poblacional.
- Error Absoluto Medio (MAE): Promedio de diferencias absolutas entre valores reales y predichos.
- Error Cuadrático Medio (RMSE): Medida de error que penaliza más los errores grandes.
- Error Porcentual Absoluto Medio (MAPE): Error porcentual promedio entre valores reales y predichos.
- Estacionariedad: Propiedad de una serie temporal donde estadísticas como la media son constantes.
- Exponential Smoothing (Suavizado Exponencial): Familia de métodos que asignan pesos decrecientes a datos pasados.

- Función de Autocorrelación Parcial (PACF): Correlación entre observaciones eliminando efectos intermedios.
- Gradient Boosting: Método de ensamble que optimiza errores residuales secuencialmente.
- Heterocedasticidad: Variabilidad no constante en los errores de un modelo predictivo.
- Hiperparámetros: Parámetros configurables de modelos de machine learning (ej: profundidad de árboles).
- Holt-Winters: Modelo de suavizado exponencial para series con tendencia y estacionalidad.
- Incidencia vs. Prevalencia: Nuevos casos vs. casos totales en un periodo determinado.
- LSTM (Long Short-Term Memory): Red neuronal recurrente para modelar dependencias temporales complejas.
- MAPE (Mean Absolute Percentage Error): Error porcentual promedio entre valores reales y predichos.
- Modelos Compartimentales: Marcos epidemiológicos como SIR o SEIR para modelar contagios.
- Normalización por Lotes (Batch Norm): Técnica para estabilizar el entrenamiento de redes neuronales.
- Overfitting (Sobreajuste): Cuando un modelo memoriza datos de entrenamiento, pero no generaliza bien.
- Poblaciones Clave: Grupos con mayor riesgo de VIH (HSH, trabajadoras sexuales, etc.).
- Precisión-Recall: Métricas para evaluar modelos de clasificación con datos desbalanceados.
- PrEP (Profilaxis Pre-Exposición): Uso preventivo de antirretrovirales en personas no infectadas.
- Prophet: Modelo de Facebook para series temporales con estacionalidad múltiple.
- Random Forest: Algoritmo de ensamble basado en múltiples árboles de decisión.
- ROC-AUC: Área bajo la curva que mide capacidad discriminativa de un clasificador.
- SARIMA (Seasonal ARIMA): Extensión de ARIMA que incorpora componentes estacionales.
- State Space Models: Marcos para modelar sistemas dinámicos con componentes observables y latentes.
- Tamizaje: Proceso de identificación temprana de casos mediante pruebas.
- TBATS: Modelo para manejar estacionalidad compleja en series temporales.
- Test de Ljung-Box: Prueba estadística para autocorrelación residual en modelos.
- Transformers: Arquitectura de redes neuronales para procesar secuencias temporales.
- Vigilancia Centinela: Monitoreo epidemiológico en puntos estratégicos del sistema de salud.
- White Noise (Ruido Blanco): Serie temporal sin autocorrelación y con variación constante.
- XGBoost: Algoritmo de boosting basado en árboles que optimiza velocidad y precisión.

# Introducción

La pandemia del Virus de Inmunodeficiencia Humana (VIH) continúa representando uno de los desafíos estructurales significativos para la salud pública en entornos urbanos como la ciudad de Medellín. La propagación responde a dinámicas epidemiológicas profundamente condicionadas por determinantes sociales, económicos y culturales, cuya interacción perpetúa patrones de desigualdad en el acceso a servicios sanitarios (Coopsana, 2023; ONUSIDA, 2023). A pesar de los avances médicos y de políticas públicas implementadas, los datos muestran una alta proporción de diagnósticos en estadios avanzados (60 %), una distribución inequitativa de pruebas rápidas y coberturas insuficientes en sectores vulnerables de la ciudad (Semana.com, 2023).

Frente a este panorama, se requieren enfoques analíticos que superen las limitaciones estructurales de los modelos predictivos convencionales, para implementar modelos es necesario hacer un análisis donde la ubicación geográfica de los casos, población afectada, es decir focalizar la problemática (Hethcote, 2000; Hyndman & Athanasopoulos, 2021). Estas deficiencias metodológicas, sumadas a la fragmentación institucional y ausencia de conectividad operativa de los sistemas de información, limitando efectividad de las estrategias de intervención, particularmente en poblaciones vulnerables como jóvenes, hombres tiene sexo con hombre (HSH), trabajadoras sexuales y migrantes (Lopera, 2019; Rojas et al., 2021).

Esta investigación plantea aplicar un modelo predictivo basado en series de tiempo para la incidencia del VIH en Medellín, combinando técnicas de inteligencia artificial (IA) y aprendizaje automático con análisis epidemiológico clásico. El objetivo es anticipar patrones de propagación de la epidemia, mediante la evaluación comparativa de modelos estadísticos (Holt-Winters, SARIMA y AutoARIMA), algoritmos de machine learning (Random Forest y XGBoost), redes neuronales profundas (LSTM y Transformers) y enfoques híbridos (Prophet), con el fin de identificar el modelo con mejor desempeño técnico y mayor aplicación práctica (Mejía et al., 2023).

Los modelos fueron evaluados con base en la capacidad predictiva y explicativa, empleando métricas como el Error Cuadrático Medio (RMSE), el Error Absoluto Medio (MAE), el Error Porcentual Absoluto Medio (MAPE) y el Coeficiente de Determinación ( $R^2$ ); , se analizaron criterios de interpretabilidad y generalización, claves para la implementación en el contexto institucional de la salud pública local. Los resultados muestran que los modelos Holt-Winters y AutoARIMA presentaron un rendimiento estable, capturando estacionalidad de la serie; mientras que Random Forest y XGBoost evidenciaron precisión en el entrenamiento; aunque con tendencia al sobreajuste y autocorrelación residual (Ruiz et al., 2022).

AutoARIMA fue seleccionado como el modelo más equilibrado por su capacidad de generalización y estabilidad en escenarios de validación cruzada. Reconoce la interpretabilidad estadística; exige experticia técnica, implicando la necesidad de acompañamiento institucional para su apropiación. En contraste, Prophet y Holt-Winters ofrecen ventajas en claridad conceptual, facilitando su comprensión por parte del personal asignado a diseñar medidas para el manejo del VIH.

Estas contribuciones abren la posibilidad de una transformación operativa en la gestión de la epidemia; los resultados permitirán optimizar estrategias de prevención a través de la identificación prospectiva de conglomerados de riesgo, racionalizar la asignación de recursos sanitarios y contribuir a una mayor equidad en el acceso a servicios. La capacidad de anticipar brotes con semanas o meses de antelación facilitará el despliegue oportuno de medidas de intervención y acciones para prevenir la propagación de manera focalizadas. Este tipo de anticipación se podría evitar; el aumento en los diagnósticos en población joven que registra un aumento de más del 40% entre 2015 y 2023; una tendencia que se identificó retrospectivamente (Semana.com, 2023).

El modelo incorpora mecanismos de reentrenamiento periódico, confiere la capacidad de adaptarse a cambios en las dinámicas de transmisión; característica es relevante en un entorno urbano en constante transformación, donde factores como la migración, turismo sexual y movilidad poblacional redefinen continuamente el panorama epidemiológico (Lopera, 2019).

Los hallazgos permiten concluir que el desarrollo de modelos predictivos en epidemiología en la población urbana no puede limitarse a la sofisticación algorítmica, se debe incorporar principios de utilidad práctica, gobernanza de datos, y justicia sanitaria; en este sentido, el modelo propuesto no sólo se configura como una herramienta de análisis, sino como una infraestructura técnica para orientar intervenciones delimitadas, anticipar brotes con semanas de antelación y optimizar la asignación de recursos en contextos de alta vulnerabilidad (Hyndman & Athanasopoulos, 2021; OMS, 2021). Esta investigación se inscribe dentro del marco de los Objetivos de Desarrollo Sostenible, particularmente en los ODS- 3 (Salud y Bienestar) y ODS-10 (Reducción de las Desigualdades), y se alinea con el Plan Decenal de Salud Pública de Colombia (2022–2031), proponiendo un enfoque metodológico replicable para otras ciudades latinoamericanas con características sociodemográficas similares. La aplicación de inteligencia artificial en contextos de salud urbana adquiere de esta forma, una dimensión estratégica, no solo como recurso analítico, sino como mecanismo de transformación institucional orientado a la equidad y la eficiencia en la respuesta sanitaria frente al VIH (ONUSIDA, 2023; Coopsana, 2023).

## Descripción del problema

La persistencia del Virus de Inmunodeficiencia Humana (VIH) como un problema crítico de salud pública en Medellín, no puede comprenderse de manera aislada. Más bien, constituye la manifestación de una compleja red de factores estructurales que interactúan de forma dinámica en un entorno urbano caracterizado por desigualdades socioeconómicas. A pesar de los avances epidemiológicos y las estrategias preventivas implementadas, el contexto epidemiológico actual continúa siendo preocupante, con una prevalencia estimada del 0,6 %, superior al promedio nacional del 0,4 %, y aproximadamente cinco nuevos diagnósticos diarios, la ciudad enfrenta una epidemia persistente que afecta de manera heterogénea a la población. Los datos agregados ocultan una realidad desigual; el VIH impacta desproporcionadamente a poblaciones históricamente marginadas, tales como hombres que tienen sexo con hombres (HSH), trabajadoras sexuales, personas transgénero y migrantes. Estas comunidades enfrentan barreras estructurales que limitan su acceso a servicios de salud, fenómeno que no debe interpretarse como un efecto colateral, sino como un reflejo directo de exclusión social, estigma y condiciones de pobreza.

Los modelos epidemiológicos convencionales no están diseñados para captar la complejidad que define esta epidemia urbana. Herramientas como los modelos compartimentales (SIR/SEIR) o los métodos de series temporales (ARIMA); aunque útiles, resultan insuficientes cuando se enfrentan a realidades sociales tan fragmentadas como la de Medellín. Algunas experiencias previas en otras ciudades, como Bogotá, han demostrado que incluso al identificar clusters de transmisión, la falta de capacidades predictivas sigue limitando una respuesta oportuna; se desaprovechan fuentes de datos emergentes como los metadatos de movilidad o las historias clínicas electrónicas que podrían enriquecer sustancialmente el análisis.

Las consecuencias de esta brecha predictiva son técnicas y humanas. Desde una perspectiva operativa, se refleja una distribución ineficiente de los recursos. No obstante, la disponibilidad herramientas diagnósticas como las pruebas rápidas, el 50 % de estas se aplican en zonas de baja incidencia, mientras que sectores de alta transmisión, como el centro de la ciudad, permanecen desatendidos. Este desfase también se evidencia en la alta proporción de diagnósticos en estadios avanzados, que alcanzan cerca del 60 %. No se trata solo de una falla logística: es una consecuencia directa de la incapacidad para anticipar y actuar. En los grupos más afectados, como los HSH (con una prevalencia del 18 %) o las trabajadoras sexuales (con una prevalencia del 5,3 %), esta falla cobra un precio elevado, ya que se intercepta con contextos de criminalidad, condiciones laborales desfavorables y ausencia de cobertura en salud.

Más allá de las limitaciones operativas, la deficiencia en la capacidad predictiva contribuye al mantenimiento prolongado de las dificultades para el acceso a servicios en salud. Las poblaciones clave no solo enfrentan una carga epidemiológica desproporcionada, obstaculizada por condiciones socioeconómicas, esta desigualdad en el acceso no solo limita la detección y el tratamiento oportuno de la epidemia, perpetuando brechas en los indicadores epidemiológicos. En Colombia, el 65 % de las personas diagnosticadas con VIH accede al tratamiento antirretroviral, cifra que se encuentra por debajo del objetivo global establecido en la estrategia 95-95-95, la cual plantea propuesta por ONUSIDA (Programa Conjunto de las Naciones Unidas sobre el VIH/SIDA) establece como meta para el año 2030 alcanzar que el 95 % de las personas que viven con VIH conozcan su estado serológico, el 95 % de aquellas diagnosticadas reciban tratamiento antirretroviral (TAR) y que el 95 % de los individuos en tratamiento logren la supresión viral, definida como carga viral indetectable. En Medellín, esta brecha es aún más pronunciada en los sectores socialmente marginados. El aumento del 40 % en los diagnósticos de VIH entre jóvenes durante el periodo 2015-2023 evidencia las dificultades del sistema de salud para implementar medidas de prevención oportunas, incluso ante patrones epidemiológicos identificados y permanentes.

La problemática adquiere un mayor nivel de complejidad de factores que reconfiguran las dinámicas de transmisión del VIH. Fenómenos como la migración intrarregional, turismo sexual y movilidad pendular entre Medellín y los municipios cercanos no solo modifican patrones tradicionales de contagio, s y limitaciones de parámetros actuales de vigilancia epidemiológica. La ausencia de articulación entre entidades territoriales y comunidad conlleva a la pérdida de oportunidades para la detección temprana e implementación de medidas e intervenciones sectorizadas y ajustadas a la dinámica de la población. En consecuencia, la epidemia escapa del monitoreo institucional precisamente en los espacios donde la acción es primordial y necesaria.

El desafío no radica únicamente en mejorar la precisión predictiva, sino en transformar esta capacidad en intervenciones oportunas, específicas y equitativas. Se trata de contar con capacidad instalada, recursos técnicos; que sean canalizadas en oportunidad, equidad, orientada a responder a las necesidades específicas de las personas en situación de vulnerabilidad epidemiológica. Los modelos epidemiológicos actuales, basados en promedios y datos agregados, carecen de capacidad para detectar la tasa de verdaderos positivos y las dinámicas cotidianas que condicionan la transmisión del virus; o toman en cuenta variables contextuales como festividades, oferta de actividades nocturnas o movilidad laboral que configuran las redes de contacto; omiten impactos derivados de la violencia, inseguridad y segregación residencial. Esta limitación metodológica genera consecuencias tangibles, el 32 % de los diagnósticos tardíos se asocian a una mayor mortalidad y costos hospitalarios elevados, afectando desproporcionadamente la capacidad económica.

La problemática local se enmarca en un contexto de compromisos globales y directrices nacionales; los Objetivos de Desarrollo Sostenible (ODS 3 “Salud y Bienestar”, tiene como



objetivo garantizar una vida sana y promover el bienestar para todas las personas en todas las edades. Esto incluye lograr la cobertura sanitaria universal, asegurar el acceso a servicios de salud sexual y reproductiva, y reducir la mortalidad infantil y materna.” y ODS10 “Reducción de las Desigualdades, tiene como objetivo reducir la desigualdad en y entre los países. Esto incluye la desigualdad de ingresos, oportunidades, y la discriminación basada en motivos como sexo, raza, edad, discapacidad o religión”), programa de Salud Pública 2022–2031, y el Plan territorial de salud de Medellín, ha establecido una hoja de ruta orientada a la reducción de inequidades en salud. No obstante, en ausencia de herramientas analíticas robustas que posibiliten intervenciones focalizadas, oportunas y basadas en evidencia, existe el riesgo de que dichos objetivos permanezcan únicamente como enunciados formales, sin una implementación efectiva que garantice su impacto real en el ámbito operativo.

Medellín cuenta con una infraestructura de salud más sólida que otras ciudades del país, si sigue siendo insuficiente para lograr un control efectivo del VIH. Los datos del Observatorio de salud pública muestran cómo las comunas pobres como la 1 -Popular, 3 - Manrique y 8 - Villa Hermosa, tienen hasta un 35 % más diagnósticos tardíos que las zonas de mayores ingresos. La implementación de estrategias de prevención en territorios de alta vulnerabilidad; el 40 % de los diagnósticos proviene de atenciones en el médico por controles tradicionales, y no de tamizajes activos, revelando un sistema reactivo; no preventivo.

El impacto de la presente problemática se evidencia en la eficiencia clínica, equidad y sostenibilidad del sistema. Cada diagnóstico tardío aumenta en un 80 %, la probabilidad de hospitalización, con un costo tres veces mayor al de un tratamiento temprano. Las poblaciones vulnerables tardan más del doble de tiempo en ser diagnosticadas, ampliando las ventanas de transmisión; y más del 20 % de los pacientes abandonan el tratamiento por barreras logísticas o económicas, perpetuando el ciclo de contagio. Se identifican cuatro brechas técnicas prioritarias: falta de resolución espacial adecuada, lentitud en la actualización de datos, baja estructuración de la información clínica y falta de adaptabilidad de los modelos actuales; estos vacíos limitan la capacidad de respuesta y subrayan la necesidad de una transformación metodológica. El presente trabajo plantea un enfoque que va más allá de lo técnico; propone una nueva manera de abordar el análisis estadístico de la epidemia; integrar técnicas de inteligencia artificial con un enfoque territorial; permite anticipar brotes, diseñar estrategias e intervenir. Por otra parte, facilita entender el VIH como un fenómeno social complejo; que exige herramientas igual de complejas y adaptativas. La persistencia en el modelo actual evidencia una limitación técnica estructural que obstaculiza la implementación eficaz de políticas públicas, comprometiendo la operatividad y alcance en contextos reales.

La metodología aplicada es mixta, de tipo no experimental y descriptiva, en la cual se miden las variables relevantes para entender la distribución y propagación del fenómeno epidémico. Se implementarán y compararán diferentes enfoques de machine learning y series temporales, evaluando su desempeño mediante métricas robustas como el Error Cuadrático Medio (RMSE), el

Error Absoluto Medio (MAE) y el Coeficiente de Determinación ( $R^2$ ). El modelo óptimo seleccionado tendrá como objetivo principal ser una herramienta práctica para las autoridades de salud pública, permitiendo anticipar brotes, optimizar la asignación de recursos y fortalecer las políticas de prevención. Aunque este estudio se limita al análisis de datos históricos y no incluye la implementación operativa del modelo, su impacto potencial es significativo. Ver Tabla 2.1.

Tabla 2.1: Matriz DOFA Problemática del VIH en la ciudad de Medellín

| Matriz DOFA Predicción del VIH en Medellín |                                                                                                                                                                                                                |
|--------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Categoría                                  | Elementos                                                                                                                                                                                                      |
| <b>Oportunidades (O)</b>                   | <b>O1:</b> Desarrollo de un modelo predictivo que permita anticipar brotes de VIH y optimizar la asignación de recursos en salud pública.                                                                      |
|                                            | <b>O2:</b> Uso de técnicas de inteligencia artificial (IA) y machine learning (ML) para mejorar la precisión de las predicciones en comparación con métodos tradicionales.                                     |
|                                            | <b>O3:</b> Posibilidad de integrar datos socioculturales y epidemiológicos para abordar los factores que influyen en la propagación del VIH.                                                                   |
|                                            | <b>O4:</b> Creación de una herramienta que pueda ser utilizada para diseñar estrategias de prevención más efectivas y focalizadas.                                                                             |
| <b>Amenazas (A)</b>                        | <b>A1:</b> Limitaciones en la calidad y disponibilidad de los datos históricos sobre la incidencia del VIH en Medellín.                                                                                        |
|                                            | <b>A2:</b> Dificultades para capturar y modelar factores no lineales y complejos, como el estigma, la discriminación y las barreras socioeconómicas.                                                           |
|                                            | <b>A3:</b> Posible resistencia por parte de las autoridades de salud para adoptar modelos basados en IA debido a la falta de familiaridad con estas tecnologías.                                               |
|                                            | <b>A4:</b> Riesgo de que el modelo no sea preciso o generalizable para ser aplicado en otros contextos o regiones.                                                                                             |
| <b>Fortalezas (F)</b>                      | <b>F1:</b> Uso de técnicas avanzadas de IA, como modelos de series temporales (ARIMA, SARIMA) y machine learning (redes neuronales, LSTM), que permiten capturar patrones complejos en los datos.              |
|                                            | <b>F2:</b> Integración de un análisis exploratorio de datos (EDA) que no solo se enfoca en los números, sino también en el contexto sociocultural de Medellín.                                                 |
|                                            | <b>F3:</b> Enfoque en la comparación de diferentes modelos para identificar cuál ofrece el mejor desempeño en términos de precisión y capacidad predictiva.                                                    |
|                                            | <b>F4:</b> Potencial para generar una herramienta que pueda ser utilizada para la toma de decisiones.                                                                                                          |
| <b>Debilidades (D)</b>                     | <b>D1:</b> Dependencia de la calidad y disponibilidad de los datos históricos, lo que podría limitar la precisión del modelo.                                                                                  |
|                                            | <b>D2:</b> Complejidad técnica asociada con la implementación y validación de modelos de IA, especialmente en un contexto donde los recursos pueden ser limitados.                                             |
|                                            | <b>D3:</b> Posible falta de interpretabilidad de los modelos de IA, lo que podría dificultar su adopción por parte de las autoridades de salud.                                                                |
|                                            | <b>D4:</b> Necesidad de actualizar continuamente el modelo con nuevos datos para mantener su precisión y relevancia.                                                                                           |
| <b>F+O</b>                                 | <b>F1+O1:</b> El uso de técnicas avanzadas de IA permitirá desarrollar un modelo predictivo que anticipe brotes de VIH y optimice la asignación de recursos en salud pública.                                  |
|                                            | <b>F2+O3:</b> El análisis exploratorio de datos (EDA) no solo ayudará a entender las tendencias numéricas, sino también a contextualizar los datos dentro del entorno sociocultural de Medellín.               |
|                                            | <b>F3+O2:</b> La comparación de diferentes modelos de IA y series temporales permitirá identificar cuál ofrece el mejor desempeño, mejorando la capacidad predictiva en comparación con métodos tradicionales. |
|                                            | <b>F4+O4:</b> La creación de una herramienta práctica basada en IA permitirá a las autoridades de salud diseñar estrategias de prevención más efectivas y focalizadas.                                         |

| Matriz DOFA Predicción del VIH en Medellín |                                                                                                                                                                                                                     |
|--------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Categoría                                  | Elementos                                                                                                                                                                                                           |
| <b>F+A</b>                                 | <b>F1+A2:</b> Aunque los modelos de IA pueden capturar patrones complejos, su capacidad para modelar factores no lineales, como el estigma y la discriminación, dependerá de la calidad de los datos disponibles.   |
|                                            | <b>F2+A1:</b> El análisis exploratorio de datos (EDA) ayudará a identificar y mitigar las limitaciones en la calidad y disponibilidad de los datos históricos.                                                      |
|                                            | <b>F3+A4:</b> La comparación de diferentes modelos permitirá seleccionar aquel que sea más generalizable y aplicable en otros contextos, reduciendo el riesgo de que el modelo no sea útil fuera de Medellín.       |
|                                            | <b>F4+A3:</b> Aunque existe el riesgo de resistencia por parte de las autoridades de salud, la creación de una herramienta práctica y fácil de usar podría facilitar su adopción.                                   |
| <b>D+O</b>                                 | <b>D1+O1:</b> Para aprovechar la oportunidad de desarrollar un modelo predictivo preciso, es necesario mejorar la calidad y disponibilidad de los datos históricos sobre la incidencia del VIH.                     |
|                                            | <b>D2+O2:</b> A pesar de la complejidad técnica asociada con los modelos de IA, su uso ofrece una oportunidad única para superar las limitaciones de los métodos tradicionales.                                     |
|                                            | <b>D3+O4:</b> Aunque los modelos de IA pueden ser difíciles de interpretar, su capacidad para mejorar la precisión de las predicciones justifica el esfuerzo de desarrollar herramientas que faciliten su adopción. |
|                                            | <b>D4+O3:</b> La necesidad de actualizar continuamente el modelo con nuevos datos representa un desafío, pero también una oportunidad para mantener su relevancia y precisión a lo largo del tiempo.                |
| <b>D+A</b>                                 | <b>D1+A1:</b> La dependencia de la calidad de los datos históricos es una debilidad que se ve exacerbada por la amenaza de la falta de datos precisos y completos.                                                  |
|                                            | <b>D2+A3:</b> La complejidad técnica de los modelos de IA podría aumentar la resistencia por parte de las autoridades de salud, especialmente si no se proporciona capacitación adecuada.                           |
|                                            | <b>D3+A2:</b> La falta de interpretabilidad de los modelos de IA podría dificultar su adopción, especialmente si las autoridades de salud no confían en las predicciones generadas.                                 |
|                                            | <b>D4+A4:</b> La necesidad de actualizar continuamente el modelo con nuevos datos representa un desafío, especialmente si los recursos para la recolección y procesamiento de datos son limitados.                  |

*Nota:* Elaboración propia a partir de la construcción del marco teórico

# Objetivos

---

## 1. Objetivo General

Aplicar un modelo de predicción para la incidencia del VIH en Medellín mediante el análisis de series de tiempo, con el fin de identificar patrones estacionales y tendencias que permitan optimizar estrategias de prevención y gestión en salud pública.

## 2. Objetivos Específicos

- Preprocesar los datos sobre la incidencia mensual del VIH en Medellín desde 2012 hasta 2022, asegurando su calidad y adecuación para el análisis de series de tiempo.
- Analizar las tendencias y patrones estacionales de los datos mediante técnicas de análisis exploratorio y visualización, de factores que puedan influir en la propagación del virus.
- Comparar distintos modelos de predicción de series temporales, incluyendo métodos estadísticos tradicionales y modelos de Machine Learning, para evaluar su desempeño y precisión en la predicción de casos futuros.
- Seleccionar el modelo en función de métricas de error y capacidad predictiva, asegurando su utilidad en la toma de decisiones en salud pública.
- Proponer recomendaciones basadas en los resultados del modelo, con el fin de planear estrategias de prevención y políticas públicas enfocadas en la reducción de la incidencia del VIH en Medellín.

## 3. Hipótesis

¿Es posible identificar, mediante la comparación de modelos de machine learning (ML) y métodos tradicionales de series temporales, un modelo predictivo que se adapte mejor a los datos históricos de incidencia del VIH en Medellín y ofrezca predicciones como herramienta aplicable para la planeación de estrategias de prevención y control de la epidemia?

## Estado del Arte

El Virus de Inmunodeficiencia Humana (VIH) representada uno de los desafíos para la salud pública global en las últimas décadas, dejando una profunda huella en el ámbito sanitario, la economía y los derechos humanos. La epidemia ha sufrido una transformación notable; inicialmente fue considerado una sentencia de muerte; hoy se ha convertido en una condición crónica que puede manejarse efectivamente, gracias a los avances científicos y terapéuticos. Sin embargo, a pesar de estos progresos, persisten desigualdades significativas al acceso a tratamientos y estrategias de prevención, particularmente en regiones vulnerables como América Latina. En ciudades como Medellín, estas brechas se ven potencializadas por factores socioeconómicos, culturales y estructurales que dificultan una respuesta integral y efectiva.

El presente estado del arte ofrece una síntesis sobre la evolución histórica del VIH y las estrategias para su prevención y control, frente a la incorporación de modelos predictivos basados en inteligencia artificial (IA) y aprendizaje automático (ML). Este enfoque tecnológico representa una oportunidad para la vigilancia epidemiológica; permite anticipar patrones de transmisión y optimizar recursos en salud pública; contextualiza la situación particular de Medellín, resaltando los retos que enfrenta la ciudad en la gestión de la epidemia y las posibilidades que brindan las nuevas herramientas analíticas para fortalecer la toma de decisiones y medir el impacto de las intervenciones.

### 4.1. Evolución Histórica de la Epidemia del VIH

#### 4.1.1. Los orígenes (1980-1990): Identificación y estigma

La historia del VIH comienza a finales de 1981, cuando los Centros para el Control y Prevención de Enfermedades (*Centers for Disease Control and Prevention* - CDC) de Estados Unidos reportaron los primeros casos de una extraña enfermedad que afectaba principalmente a hombres jóvenes homosexuales, caracterizada por *Pneumocysti* (*Pneumocystis jirovecii*) y sarcoma de Kaposi (CDC, 1981). Esta presentación inicial fue erróneamente etiquetada como “enfermedad de homosexuales”; un estigma que, según Shilts (1987), dificultó la comprensión científica, disminuyó la respuesta política y social. Kramer (1989) documenta cómo esta estigmatización contribuyó a una inacción gubernamental que amplificó el impacto de la epidemia durante esta década.

En 1983, se dio un paso crucial cuando el equipo del Dr. Luc Montagnier en el Instituto Pasteur aisló el virus causante, inicialmente denominado Virus asociado a la linfadenopatía –

(*Lymphadenopathy Associated Virus*) - LAV, confirmando su existencia poco después el Dr. Robert Gallo con la identificación del virus linfotrópico T humano- (*Human T-cell Lymphotropic Virus type III* –(HTLV-III) (Barré-Sinoussi et al., 1983). No obstante, de este avance científico, la ausencia de tratamientos efectivos y una mortalidad que superaba el 80% en dos años convirtieron a esta época en una de las más sombrías para quienes vivían con el virus. Los primeros intentos por modelar la propagación del VIH, como los descritos por Anderson y May (1988), resultaron insuficientes, porque no consideraron la complejidad social y conductual, como la heterogeneidad de las redes de contacto sexual y el uso de drogas intravenosas; factores clave en la dinámica real de la epidemia.

#### **4.1.2. La revolución antirretroviral (1990-2000): De la fatalidad a la condición crónica**

El contexto de la epidemia cambió radicalmente en 1996 con la introducción de la terapia antirretroviral de alta eficacia (TARAA), que transformó la perspectiva del VIH de una enfermedad fatal a una condición crónica manejable. El estudio pionero de Palella et al. (1998) evidenció una reducción del 60% en la mortalidad en países desarrollados, una esperanza que tardó en llegar a las naciones con menos recursos, donde el acceso a estos tratamientos era inferior al 5% (ONUSIDA, 2001). Paralelamente, los modelos epidemiológicos comenzaron a evolucionar; Blower et al. (2000) se introdujo el concepto de “*tratamiento como prevención*”, reconociendo el potencial de la Terapia antirretroviral de gran actividad (*Highly active antiretroviral therapy* – TARAA) para reducir la transmisión. Estos modelos no contemplaron aspectos como la adherencia al tratamiento y la aparición de resistencia viral.

Las profundas desigualdades globales frente a la epidemia mencionada durante la Conferencia Internacional de SIDA en Durban (2000), el presidente sudafricano Thabo Mbeki puso en duda la relación causal entre VIH y SIDA, dificultando la implementación de políticas efectivas (Nattrass, 2004). El alto costo de los antirretrovirales —que superaba los 10,000 dólares anuales por paciente— limitó la accesibilidad, hasta la llegada de medicamentos genéricos en 2001 que abrió una nueva etapa en la lucha contra la epidemia (Attaran & Gillespie-White, 2001).

#### **4.1.3. Prevención combinada (2000-2010): Enfoques multidimensionales**

Durante la década del 2000, la prevención del VIH experimentó avances significativos a partir de estrategias multidimensionales que combinaban diferentes intervenciones para reducir la transmisión. Uno de los hitos más importantes fue la demostración de la circuncisión masculina podía reducir la transmisión heterosexual en un 60%, según los estudios de Auvert et al. (2005). Paralelamente, la profilaxis preexposición (PrEP) emergió como una herramienta prometedora, mostrando una eficacia del 44% en la prevención del VIH en poblaciones de alto riesgo, según Grant et al. (2010).

A finales de esta década, el estudio HIV denominado Red de ensayos de prevención del VIH (*Prevention Trials Network*) -HPTN 052; aportó evidencia contundente sobre el efecto preventivo

del tratamiento antirretroviral, confirmando que una carga viral indetectable disminuye la transmisión en un 96% (Cohen et al., 2011). Estos hallazgos transformaron la perspectiva de la prevención, evidenciando la necesidad de combinar diferentes estrategias para maximizar el impacto.

Los modelos epidemiológicos comenzaron a evolucionar, incorporando micro simulaciones y análisis de redes sociales. Enfermedades de transmisión sexual (*sexually transmitted diseases*) - STDSIM, desarrollado por Kretzschmar y Morris (1996), permitió analizar dinámicas de transmisión a nivel individual y comunitario, revelando la importancia de diseñar intervenciones específicas para subpoblaciones vulnerables (Goodreau et al., 2012). Esta generación de modelos puso en evidencia que las estrategias generalistas eran insuficientes para responder a la heterogeneidad de la epidemia.

#### **4.1.4. Era de la IA (2010-2020): Modelos predictivos y desafíos éticos**

Esta década estuvo marcada por la irrupción de la inteligencia artificial (IA) en la epidemiología del VIH, abriendo una nueva frontera en la capacidad predictiva y analítica. Zhang et al. (2018) demostraron que las redes neuronales, memoria a corto y largo plazo (*Long short-term memory*) – LSTM; podían predecir brotes con un 23% más de precisión que los modelos epidemiológicos tradicionales, gracias a la capacidad para manejar datos temporales complejos y no lineales.

La implementación de estas tecnologías plantea nuevos desafíos, la necesidad de grandes volúmenes de datos para entrenar los modelos y el riesgo inherente de sesgos algorítmicos generaron preocupaciones éticas y técnicas que no pueden ser ignoradas (Mehra et al., 2020). En América Latina, algunos países, como Brasil, comenzaron a explorar modelos híbridos combinando métodos estadísticos clásicos como ARIMA con algoritmos de aprendizaje automático como XGBoost (Santos et al., 2021). En ciudades como Medellín, los esfuerzos por incorporar la inteligencia artificial (IA) en la vigilancia y predicción del VIH han sido limitados, evidenciando una brecha entre el potencial tecnológico y la aplicación en contextos locales (Ruiz et al., 2022).

#### **4.2. Modelos Predictivos en la Epidemiología del VIH: Avances, limitaciones y oportunidades**

Los modelos predictivos han evolucionado notablemente en las últimas décadas, pasando de enfoques estadísticos tradicionales a complejos sistemas basados en IA. De igual manera los modelos clásicos compartimentales, como SIR (Susceptible-infectado-recuperado) y SEIR (Susceptible-expuesto-infectado-recuperado), desarrollados por Hethcote (2000), fueron pioneros al describir el comportamiento de transmisión del VIH. Estos modelos presentan limitaciones significativas; asumen una transmisión homogénea y no logran capturar factores esenciales como las redes de contacto sexual, consumo de drogas intravenosas o desigualdades socioeconómicas. Es una situación visible en Medellín, donde la epidemia se concentra en poblaciones, como



hombres que tienen sexo con hombres (HSH), trabajadoras sexuales entre otros, cuyas dinámicas no reflejan adecuadamente en modelos tradicionales (Rojas et al., 2021).

Para mejorar las predicciones, se ha empleado modelos de series temporales como ARIMA (AutoRegressive integrated moving average), que son útiles para anticipar tendencias a corto y mediano plazo (Box et al., 2015). Estos modelos enfrentan dificultades cuando los datos presentan saltos abruptos o relaciones no lineales, como ocurre en eventos masivos o migraciones estacionales. En Medellín, durante la Feria de las Flores se ha observado un aumento en diagnósticos de VIH, posiblemente asociado al incremento de interacciones sexuales casuales y consumo de alcohol (Secretaría de Salud de Medellín, 2022), un fenómeno complejo para los modelos tradicionales.

Frente a estas limitaciones, el aprendizaje automático (ML) ha surgido como una alternativa prometedora. Algoritmos como Random Forest y XGBoost han demostrado su capacidad para identificar factores de riesgo y predecir diagnósticos tardíos con alta precisión. Powers et al. (2015), aplicaron Random Forest en datos de Sudáfrica, encontrando que variables como la circuncisión masculina y el acceso a pruebas de VIH eran predictores de nuevas infecciones. Feller et al. (2018) lograron una precisión del 82% en la predicción de diagnósticos tardíos en EE. UU, de igual manera usando XGBoost, superando a métodos estadísticos tradicionales. Los modelos requieren datos estructurados y consistentes, un desafío en América Latina, donde la fragmentación de los sistemas de salud dificulta la recopilación de información fiable. (Ruiz et al., 2022).

Las redes neuronales recurrentes, especialmente las LSTM (Long Short-Term Memory), han mostrado un potencial revolucionario para captar dependencias temporales no lineales. Zhang et al. (2021) desarrollaron un modelo LSTM que analizó datos de San Francisco entre 2010 y 2019, superando en un 23% la precisión de ARIMA. Estas redes son ideales para modelar cambios en políticas o comportamientos de riesgo, pero requieren grandes volúmenes de datos y capacidad computacional, recursos limitados en contextos como Medellín, donde la vigilancia epidemiológica sigue fragmentada (Mejía et al., 2023).

Una vía innovadora es la creación de modelos híbridos que combinan métodos estadísticos y de IA. Santos et al. (2023) combinaron SARIMA con redes neuronales para corregir subregistros en Brasil, mejorando la precisión en un 15%. Este tipo de enfoque puede ser fundamental en Medellín, donde el subregistro alcanza el 25-30% en poblaciones expuestas (INS, 2021). Las técnicas como los grafos temporales, usadas por Kompella et al. (2022) para identificar “superpropagadores” en redes de transmisión, ofrecen una oportunidad para adaptar estrategias a la complejidad social y urbana de la ciudad.

#### **4.3. Contexto Local: La Epidemia del VIH en Medellín y sus desafíos únicos**

Medellín enfrenta una epidemia de VIH con características propias que requieren una atención diferenciada. La prevalencia en la ciudad es de aproximadamente 0.6%, superior al promedio




nacional del 0.4% (Secretaría de Salud de Medellín, 2023). Los hombres que tienen sexo con hombres (HSH) representan cerca del 42% de los nuevos diagnósticos, seguidos por trabajadoras sexuales y personas transgénero, grupos que enfrentan barreras estructurales profundas, como el estigma, discriminación y limitaciones en el acceso a servicios de salud (García et al., 2022).

Un dato alarmante es que el 42% de los diagnósticos corresponden a infecciones recientes, lo que indica una transmisión activa y poco detectada (García et al., 2022). Entre las causas, destacan el inicio temprano de la vida sexual, bajo uso constante de condones en jóvenes y baja cobertura de estrategias de prevención combinada, incluyendo la profilaxis preexposición al VIH (PrEP) (Paz-Bailey et al., 2019). La pandemia de COVID-19 agravó esta situación, provocando una caída del 40% en las pruebas de VIH en 2020 (INS, 2021), lo que probablemente incrementó la cantidad de casos sin diagnosticar.

La distribución geográfica de los casos evidencia desigualdades socioeconómicas. Comunas como Manrique, Aranjuez, Robledo y Villa Hermosa, con altos niveles de pobreza y marginalidad; presentan las tasas de incidencia más elevadas (Semana.com, 2023). En estas zonas, falta de educación sexual integral, consumo de drogas inyectables y turismo sexual; son factores que alimentan la propagación del virus. Por otro lado, en estratos altos, como El Poblado, la epidemia se relaciona más con redes sexuales altamente conectadas entre HSH (Rojas et al., 2021).

Figura 4.1: Casos de VIH por Comuna



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Al observar el mapa que representa la distribución de los casos de VIH en Medellín, se hace evidente una marcada concentración en ciertas zonas de la ciudad. Los tonos más oscuros, que indican una mayor cantidad de casos, se encuentran en su mayoría en el área central, especialmente en la comuna de La Candelaria. Esta comuna, que corresponde al centro de Medellín, concentra más de 1200 casos, convirtiéndose en el foco principal de la epidemia en términos territoriales. Esta concentración no parece ser aleatoria; al contrario, responde a condiciones sociales, económicas y culturales específicas que se entrelazan en este sector.

El centro de la ciudad no solo alberga una gran densidad poblacional, sino que también es escenario de dinámicas sociales complejas, incluyendo un alto flujo migratorio, presencia de población habitante de calle, comercio informal y una actividad nocturna significativa. Todos estos factores pueden contribuir a una mayor exposición al virus y dificultan, a su vez, el acceso continuo a servicios de salud. Por lo tanto, este hallazgo reafirma que el comportamiento del VIH en Medellín no solo puede leerse desde las cifras, sino también desde la geografía y las condiciones de vida de quienes habitan cada territorio.

También se observa que comunas como Belén, Villa Hermosa, Buenos Aires y Aranjuez presentan una carga importante de casos. Estas zonas, aunque menos críticas que La Candelaria, muestran una intensidad significativa, lo cual sugiere que el problema no se limita a un solo punto, sino que se extiende por varios sectores urbanos que comparten ciertos niveles de vulnerabilidad. Esto plantea la necesidad de pensar en intervenciones regionales y no únicamente centralizadas, priorizando aquellas zonas donde confluyen los factores de riesgo y el aumento progresivo de casos.

En cambio, los corregimientos ubicados en la periferia de la ciudad, como San Antonio de Prado, Altavista, San Cristóbal y Santa Elena, muestran tonalidades mucho más claras, lo que indicaría un número menor de casos registrados. Sin embargo, este dato debe leerse con cautela. Aunque podría interpretarse como una menor incidencia, también es posible que en estos territorios se presenten mayores barreras en el acceso a servicios de diagnóstico o que exista un subregistro significativo, lo que invisibiliza parcialmente la situación real.

El mapa, más allá de ser una herramienta visual, es una forma de narrar el impacto del VIH en la ciudad desde una perspectiva espacial. Muestra con claridad que la epidemia no se distribuye de manera uniforme, sino que responde a una lógica territorial que está profundamente conectada con las dinámicas urbanas y sociales de Medellín. Este tipo de representación permite dimensionar el problema desde un enfoque más integral, resaltando la necesidad de implementar estrategias diferenciadas según el contexto de cada comuna o corregimiento.

A pesar de los esfuerzos, persisten vacíos significativos en la respuesta local. La fragmentación de los sistemas de información entre aseguradoras y entidades sanitarias dificulta un monitoreo en tiempo real. No existen modelos predictivos específicos que integren variables relevantes como movilidad urbana o factores sociodemográficos, limitando la capacidad de anticipar brotes o

diseñar intervenciones, es necesario revisar (Mejía et al., 2023). Las experiencias de otras ciudades como São Paulo, emplean series temporales jerárquicas para mejorar la vigilancia (Machado et al., 2020), muestran un camino para generar avances en la ciudad de Medellín.

#### **4.4. Inversión pública en salud y políticas de prevención en Medellín: una revisión histórica**

Desde el año 2012, Medellín ha experimentado un crecimiento sostenido en la inversión pública destinada al sector salud, particularmente en áreas asociadas con la salud pública, la prevención de enfermedades y el fortalecimiento de programas sociales. Esta evolución presupuestal no solo responde a necesidades epidemiológicas específicas, sino que también refleja un compromiso progresivo de la administración municipal por garantizar el bienestar colectivo, reducir brechas sociales y atender de manera integral los determinantes sociales de la salud.

En los primeros años del período analizado, los recursos destinados a salud pública eran relativamente limitados. Por ejemplo, en 2012, los aportes provenientes del Sistema General de Participaciones (SGP) para salud pública y atención a población no afiliada se situaban entre los 27 y 30 mil millones de pesos (Gobernación de Antioquia, 2012). A pesar de que estas cifras pueden parecer modestas desde la perspectiva actual, en su momento representaban un avance importante en la consolidación de estrategias preventivas básicas.

Entre 2012 y 2016, los gobiernos locales comenzaron a consolidar programas con enfoque preventivo, tales como Vida Sana, Sonrisa Saludable y acciones integrales en salud mental y redes de urgencias. Este período fue clave para posicionar la prevención y promoción de la salud como ejes fundamentales en la política pública municipal (Alcaldía de Medellín, 2016). Además, se comenzó a trabajar con mayor énfasis en las poblaciones más vulnerables, ampliando la cobertura y mejorando la accesibilidad a los servicios básicos.

La pandemia por COVID-19 marcó un punto de inflexión decisivo. En 2019, el presupuesto destinado al sector salud alcanzaba los 814 mil millones de pesos (valores constantes de 2020), representando el 15,1 % del total del presupuesto municipal. Para 2020, esta cifra ascendió drásticamente a 1,077 billones de pesos, incrementando su participación al 21,8 % (Dejusticia, 2022). Este aumento no solo fue una respuesta inmediata a la emergencia sanitaria, sino también una muestra del reconocimiento institucional sobre la importancia de robustecer el sistema de salud pública ante situaciones de alto impacto social. A nivel individual, el gasto per cápita también reflejó esta priorización, al pasar de 328 mil pesos en 2019 a 425 mil en 2020.

En los años siguientes, aunque se evidenció una leve disminución porcentual en la asignación presupuestal, el valor absoluto continuó en aumento. Para 2022 y 2023, Medellín destinó aproximadamente 1,4 billones de pesos anuales al sector salud (Dejusticia, 2022). Estos recursos siguieron enfocados en el fortalecimiento de programas de vigilancia epidemiológica, prevención de enfermedades transmisibles y no transmisibles, control de zoonosis y promoción de la salud juvenil, entre otros frentes de acción relevantes para la ciudad (Alcaldía de Medellín, 2023a).

Finalmente, para el año 2025, el Concejo de Medellín aprobó un presupuesto total de 10,96 billones de pesos, de los cuales 1,58 billones están asignados al sector salud (Concejo de Medellín, 2024). Esta cifra, además de representar un crecimiento del 25 % respecto al año anterior, constituye el punto más alto en la historia presupuestal reciente del municipio para este rubro. El enfoque estratégico para 2025 contempla, además de la atención médica, una inversión significativa en prevención, salud mental, infraestructura, salud pública comunitaria y programas sociales con énfasis en equidad y justicia social (Alcaldía de Medellín, 2023b).

En síntesis, el análisis del comportamiento presupuestal en salud en Medellín entre 2012 y 2025 permite evidenciar una tendencia positiva en términos de inversión, tanto en volumen como en enfoque. Esta evolución ha sido coherente con las transformaciones epidemiológicas de la ciudad y se alinea con una visión de salud pública que trasciende lo asistencial para convertirse en un instrumento de transformación social.

#### **4.5. Discusión: Hacia una respuesta integral con enfoque humano y tecnológico**

La incorporación de herramientas tecnológicas en respuesta al proceso de incidencia del VIH; donde el enfoque humano toma relevancia para atender los determinantes sociales y estructurales de la epidemia. Los modelos predictivos basados en IA ofrecen un gran potencial; es fundamental que estas tecnologías se integren con intervenciones comunitarias que combatan el estigma, faciliten el acceso a servicios y promuevan la educación sexual. El fortalecimiento de los sistemas de vigilancia epidemiológica es fundamental mediante plataformas unificadas que integren datos clínicos, comportamentales y de movilidad.

El análisis de datos de transporte público, como los del metro de Medellín, podría contribuir a modelar patrones de contacto poblacional y anticipar brotes (Mejía et al., 2023). El uso de técnicas de procesamiento de lenguaje natural (NLP) en informes clínicos no estructurados podría revelar tendencias ocultas que escapan al análisis convencional. La aplicación de IA debe estar regida por principios éticos rigurosos que eviten la perpetuación de sesgos y estigmas, especialmente hacia poblaciones vulnerables; los esquemas de gestión pública con el propósito de asegurar transparencia, equidad y responsabilidad en el manejo de datos, apoyándose en principios como los FAIR (Findable, accesible, interoperable, reusable) de la OMS (2021). Es esencial involucrar a las comunidades afectadas en el diseño y ejecución de políticas, así como los Programas y desarrollos de la Corporación Stonewall (2021), que combina educación sexual con la reducción del estigma; ha demostrado ser exitosos y podrían replicarse o ampliarse en Medellín, en las comunas con alta incidencia y acceso limitado a servicios.

#### **4.6. Marco Legal y Ético: Fundamentos para una investigación responsable**

La investigación y las intervenciones en VIH en Medellín deben estar respaldadas por un marco legal y ético que proteja los derechos de las personas afectadas. La Constitución Política de Colombia (1991) garantiza el derecho fundamental a la salud (Artículo 49), la Ley 100 (1993)

promueve el acceso universal a servicios de salud, incluyendo pruebas y tratamiento antirretroviral, y la Ley 1581 (2012) regula el manejo de datos personales, enfatizando el consentimiento informado y la confidencialidad, principios esenciales en el trabajo con poblaciones vulnerables.

Los Objetivos de Desarrollo Sostenible (ODS), el ODS-3, compromete a Colombia a reducir la transmisión del VIH y asegurar la salud sexual y reproductiva para todos, la realidad local refleja que persisten brechas importantes; la Ley 1482 (2011) prohíbe la discriminación por estado de salud, muchas personas con VIH siguen enfrentando exclusión laboral y social (Corporación Stonewall, 2021), y desde la perspectiva ética, la Resolución 8430 de 1993 exige que toda investigación en salud sea evaluada por comités independientes, crucial en estudios que incorporan IA; donde la transparencia en el uso de datos es fundamental para evitar situaciones no ajustadas a las problemáticas. En Medellín, la colaboración entre universidades, autoridades sanitarias y organizaciones sin ánimo de lucro podría consolidar estos mecanismos, reforzando que los avances tecnológicos beneficien a la población vulnerable.

## Justificación

Esta investigación surge con el propósito de proponer la aplicación de herramientas que contribuyan y actúen como un mecanismo de predicción y detección de posibles nuevos casos; un modelo predictivo que permita anticiparse a la evolución del VIH en Medellín. Esta propuesta busca promover un enfoque de análisis e intervención que contemple aspectos sociales de la población afectada y fomente respuestas institucionales equitativas. técnica Esta propuesta integra técnicas de inteligencia artificial con enfoques estadísticos tradicionales, la convergencia metodológica permite combinar analítica de los modelos clásicos con la flexibilidad y capacidad adaptativa de las tecnologías emergentes. (Zhang et al., 2022).

La perspectiva social, busca aplicar una herramienta para la promoción y equidad en salud; identificar zonas de riesgo, anticipación de brotes y orientación estratégica de las intervenciones; que brinden asignar recursos y acciones en las poblaciones con mayor vulnerabilidad; donde la mitigación del impacto del virus y la disminución de las cargas asociadas al estigma y la exclusión social. En el plano institucional, la propuesta está alineada con políticas y compromisos nacionales e internacionales. Responde a los Objetivos de Desarrollo Sostenible (ODS 3 y 10), metas de ONUSIDA (95-95-95), y a los planes de salud pública de Medellín y Colombia, que promueven el uso de tecnologías emergentes para mejorar vigilancia y respuesta en salud (MinSalud, 2022; ONUSIDA, 2023).

Esta propuesta brinda una visión en la transformación con enfoques convencionales para comprender y aborda el VIH en la ciudad de Medellín, mediante la adopción de una perspectiva ética, territorial, que incorpora una perspectiva en la formulación de respuestas integrales, conforme a los principios de la OMS.

Plantea de una alternativa en la necesidad dar respuesta integrando dimensiones sociales, culturales y organizacionales que influyen en la transmisión, diagnóstico y tratamiento del VIH, con un enfoque situado y humanizado, buscando fortalecer capacidades locales, fomentar la participación comunitaria y orientación de políticas públicas hacia intervenciones sostenibles.

# Alcances y Limitaciones

## 6.1 Alcance

Esta investigación aplicará un modelo predictivo que estima la incidencia mensual del VIH en Medellín entre 2012 y 2022; comparando enfoques estadísticos clásicos y modelos de machine learning, para evaluar cuál ofrece mejores resultados y evaluará el desempeño del modelo con indicadores como RMSE, MAE, MAPE y  $R^2$ , con la finalidad de ser usado por las autoridades de salud para tomar decisiones informadas.

## 6.2 Limitaciones

La calidad del modelo dependerá de los datos disponibles. Existen vacíos de información y subregistro, especialmente en población flotante como la comunidad migrante.

- El modelo está diseñado para la ciudad de Medellín, la aplicación en otras ciudades requerirá ajustes metodológicos.
- Contempla factores determinantes del VIH como el estigma, violencia y patrones culturales que no son incluidos en el modelo actual.
- La implementación institucional del modelo requerirá procesos posteriores de validación, formación y análisis de los niveles de compromiso político-institucional.

# Metodología y Desarrollo

## 7.1. Fase de entendimiento de la situación

### 7.1.1 Contextualización del problema

El VIH representa un reto en la gestión de la salud pública a nivel mundial, donde la prontitud y aplicación de las medidas de intervención, frente el diagnóstico oportuno, tratamiento precoz y principalmente la promoción de la salud y la prevención de la enfermedad; la epidemia persiste con un impacto desigual en las poblaciones vulnerables. Según ONUSIDA (2023), alrededor de 39 millones de personas viven actualmente con el virus, y cada año se reportan cerca g de 1,3 millones de nuevas infecciones; preocupa que muchas de estos contagios se concentran en contextos marcados por pobreza, exclusión social y discriminación estructural. El acceso desigual a información, la estigmatización y barreras para recibir atención médica, continúan siendo factores determinantes en la propagación del VIH, especialmente en los países con mayor reporte. América Latina no ha sido ajena a esta realidad. En los últimos años, la región ha mostrado avances en cobertura de tratamientos antirretrovirales; enfrenta dificultades para contener el número de nuevos contagios. La Organización Panamericana de la Salud (OPS, 2022) advierte que, lejos de estabilizarse, la epidemia muestra signos de emergencia en varios países, revelando la necesidad urgente de fortalecer los sistemas de vigilancia epidemiológica donde adopten enfoques contextualizados y sensibles a las realidades sociales de cada territorio.

En Colombia, el contexto epidemiológico es complejo, se ha adoptado políticas integrales de respuesta al VIH y ha mejorado el acceso a diagnóstico y a tratamiento, aunque las cifras siguen siendo preocupantes. El Instituto Nacional de Salud (INS, 2023) reporta una prevalencia del 0,4% en la población general, pero con marcadas diferencias entre regiones y grupos poblacionales. Gran parte de los casos nuevos se diagnostican en etapas avanzadas de la infección, lo que indica fallas en la detección oportuna y en las estrategias de prevención; persiste una brecha significativa entre el diseño de las políticas públicas y la implementación en territorios donde las desigualdades sociales se expresan con mayor crudeza.

En este contexto, Medellín, una ciudad reconocida por los avances en innovación social y urbanismo, enfrenta una paradoja; a pesar de la capacidad institucional y de las políticas públicas, el VIH continúa afectando de manera recurrente en sectores vulnerables de la población. La ciudad presenta una tasa de prevalencia del 0,6%, por encima del promedio nacional, esto equivale a cinco nuevos contagios diarios, de los cuales el 45% ocurre en personas jóvenes entre los 20 y 29 años




(INS, 2023); el acceso a tecnologías, información y educación no evita que los jóvenes resulten expuestos a nuevos riesgos sociales, especialmente a salud sexual y reproductiva,

La problemática no se distribuye de forma homogénea; las comunas con mayor incidencia detectan mejorías en el acceso a salud, educación sexual integral y condiciones de vida dignas, sigue siendo limitado. La caracterización de la población la constituyen jóvenes, migrantes, LGBTIQ+, trabajadoras sexuales y usuarios de drogas los cuales se ven expuestos a múltiples formas de exclusión que aumentan su inerte capacidad frente al virus.

En un entorno urbano tan dinámico como Medellín, donde la movilidad laboral, la migración interna y el turismo sexual forman parte del entramado cotidiano, el VIH no puede abordarse únicamente desde un enfoque clínico-asistencial. Constituye, en gran medida, un reflejo de las inequidades estructurales que atraviesan la vida urbana; cualquier estrategia de intervención debe partir del reconocimiento, detrás de cada dato, hay una persona, historia y comunidad que merece ser documentada, escuchada y protegida.

### 7.1.2. Identificación del problema

Figura 7.1: Línea del tiempo evolución del VIH



*Nota: Elaboración propia a partir de la construcción del marco teórico*

A nivel global, el abordaje del VIH ha transitado de una emergencia sanitaria a una lucha prolongada por la equidad en salud. El acceso a tratamiento antirretroviral ha mejorado notablemente en las últimas décadas, salvando millones de vidas. No obstante, una preocupación creciente persiste; el retraso en los diagnósticos. En muchas regiones del mundo, especialmente en contextos con sistemas de salud fragmentados o subfinanciados, las personas continúan recibiendo

el diagnóstico cuando la infección ya ha avanzado considerablemente, lo cual limita las posibilidades de un tratamiento efectivo y favorece la transmisión del virus de manera silenciosa (ONUSIDA, 2023).

Esta tendencia se replica en América Latina, donde la falta de integración entre los sistemas de información, las brechas territoriales y la concentración de recursos en zonas urbanas centrales dificultan la implementación de estrategias preventivas sostenidas. Los esfuerzos institucionales suelen estar limitados por el uso de herramientas analíticas que no permiten anticipar con precisión el curso de la epidemia ni focalizar las intervenciones (OPS, 2022), independiente del compromiso político en la región, las respuestas suelen ser reactivas no de carácter preventivo.

En Colombia, los modelos de predicción y vigilancia actuales aplican herramientas estadísticas convencionales, que ofrecen un panorama general limitado del comportamiento del virus; la falta de articulación entre los diversos actores del sistema de salud, Entidades Promotoras de Salud (EPS), Instituciones Prestadoras de Servicios (IPS) y entes territoriales muchas veces operan con sistemas de información no interoperables, generando una visión fragmentada de la realidad epidemiológica (MinSalud, 2021); constituyéndose en un obstáculo crucial para el diseño de políticas públicas, sin la visión integral y coordinada del fenómeno, las respuestas institucionales resultan fragmentadas y descoordinadas. No se trata únicamente de disponer de más información, sino de contar con datos relevantes, oportunos y contextualizados.

Este conjunto de dificultades se manifiesta en Medellín; la ciudad ha emprendido esfuerzos notables para combatir la epidemia; campañas educativas, jornadas de pruebas rápidas, distribución de condones, y acceso garantizado al tratamiento antirretroviral entre otros. La limitación estructural y la capacidad de anticipación a los cambios del virus, e prever hacia dónde se desplaza la epidemia, y la actuación con enfoque territorial e interseccional son resistentes

Según datos recientes, cerca del 60% de los diagnósticos de VIH en Medellín se realizan en etapas clínicas avanzadas (INS, 2023), esta cifra no representa una estadística; es el reflejo de vidas que han atravesado años con el virus sin saberlo, sin tratamiento, sin contención médica ni social. Y cuando se detecta la infección, en muchos casos ya hay complicaciones, afectaciones inmunológicas graves, y cadenas de transmisión activas que pudieron haberse interrumpido. Existe un desajuste en la distribución de recursos: mientras se realizan campañas en sectores de baja prevalencia, otras zonas de alta concentración de casos como el centro de la ciudad o comunas periféricas siguen presentando necesidades relacionadas con la ausencia de cobertura necesaria; dicha desproporción se agrava cuando no se cuenta con datos actualizados, integrados y georreferenciados que prioricen territorios y población expuesta. Frente a una epidemia que cambia de rostro constantemente, se requieren de herramientas que ayuden a entender el fenómeno y anticipar su comportamiento.

## 7.2. Fase Entendimiento de los Datos

### 7.2.1. Recopilación de Datos

El primer paso en el desarrollo del modelo predictivo fue la recopilación, análisis y comprensión detallada del conjunto de datos. Para el estudio sobre la epidemia del VIH en Medellín, los datos se tomaron de la plataforma de datos abiertos de Colombia, del conjunto de datos "VIH - SIDA", que proporciona información sobre pacientes con diagnóstico confirmado de VIH atendidos en las Instituciones Prestadoras de Servicios de Salud de la ciudad.

El conjunto de datos proviene de un seguimiento mensual de casos registrados desde el año 2012 hasta 2022, se analizó la tendencia a lo largo del tiempo, específicamente para explorar la evolución de casos a lo largo de los años.

Se utilizó como fuente principal los datos de la página web <https://medata.gov.co/node/16579>, donde se encuentran la información consignada por la Administración de la Alcaldía de la ciudad de Medellín; (DATASET VIH.xlsx), y proporcionado por entidades oficiales encargadas de la vigilancia epidemiológica. Después de la exploración inicial, se identificaron las variables clave en el dataset, tales como; semana epidemiológica, año, mes, estrato socioeconómico, sexo, grupo etario, nacionalidad y población proyectada (en formato numérico y de texto); este conjunto de datos constituía la base para realizar limpieza, análisis descriptivo y la posterior modelación. La estructura del dataset permite abordar el fenómeno del VIH desde una perspectiva temporal, espacial y sociodemográfica, lo que resulta indispensable para extraer patrones útiles en la predicción.

### 7.2.2. Limpieza del Dataset

El proceso de limpieza de datos fue crucial para garantizar la integridad y calidad de la información analizada. Normalización de nombres de columnas: eliminación de espacios en blanco innecesarios y asignó un nuevo nombre a las columnas para estandarizar el formato (por ejemplo, mes/caso se renombró a mes/num y Población a Poblacion).

Eliminación de registros vacíos: Se descartaron filas vacías para reducir el ruido en el análisis.

Conversión de tipos de datos: Se convirtieron las columnas numéricas relevantes (Semana/Año, mes/núm., /Población) a tipo entero, controlando los valores faltantes mediante la imputación con ceros y manejo de errores.

Estandarización de variables categóricas:

- Columna Estrato, se realizó limpieza reemplazando valores vacíos o inconsistentes con la categoría "No especificado".

- Columna Sexo, los valores fueron convertidos a mayúsculas y homogeneizados, transformando las abreviaturas 'M' y 'F' en 'MASCULINO' y 'FEMENINO'.
- Columna Nombre Nacionalidad fue convertida a mayúsculas y ajustada con el valor "Desconocido" para los registros con valores faltantes.

Este proceso de limpieza permitió obtener un conjunto de datos coherente, sin registros atípicos evidentes y en formato para el análisis exploratorio y modelado predictivo posterior. La limpieza implicó corrección de errores, decisiones sobre representación la información faltante o ambigua, preservando la utilidad analítica del conjunto de datos.

### 7.2.3. Análisis Descriptivo

El análisis descriptivo constituye la comprensión inicial del fenómeno estudiado. En este caso, los datos sobre el VIH en Medellín entre 2012 y 2022 ofrecen una visión del comportamiento epidemiológico de la enfermedad, con variables que permite desentrañar patrones temporales, sociodemográficos y poblacionales. El dataset analizado está compuesto por 14,491 registros completos, sin presencia de valores nulos, siendo una fortaleza metodológica relevante para los análisis posteriores. Las diez variables disponibles abarcan dimensiones temporales (semana, año, mes, día), demográficas (nacionalidad, sexo, grupo etario, estrato socioeconómico), y una variable de población que representa proyecciones demográficas por período. Esta composición permite abordar el análisis desde múltiples ángulos, con potencial significativo para identificar grupos vulnerables y tendencias emergentes.

#### *Perfil demográfico de los casos*

Dentro de los hallazgos más consistentes es el marcado predominio de casos en hombres jóvenes entre los 20 y 34 años, que concentran el 61.1% de todos los registros de esta distribución etaria y de género es coherente con las rutas de transmisión sexual predominantes del VIH y pone de relieve la necesidad de intervenciones direccionadas en esta población. La proporción por sexo revela una notable disparidad de género, donde 84.8% de los casos corresponden a hombres y solo el 15.2% a mujeres, reafirmando lo documentado en la literatura internacional sobre la concentración de la epidemia en hombres que tienen sexo con hombres (HSH) y otras poblaciones vulnerables, se detecta un grupo de riesgo adicional los adolescentes entre 15 y 19 años, que representan un 4.95% de los registros, una proporción significativa considerando el grupo etario y el contexto preventivo. Este hallazgo sugiere la necesidad urgente de reforzar programas educativos y de promoción de la salud y prevención de la enfermedad en poblaciones jóvenes antes del inicio de la vida sexual activa.

#### *Condiciones socioeconómicas y nacionalidad*

El análisis del estrato socioeconómico, limitado por la alta proporción de valores no especificados (50.7%), evidencia que los casos tienden a concentrarse en los estratos 2 y 3, que

agrupan el 38.5% de los registros con información válida. Este patrón subraya la relación entre condiciones de vulnerabilidad social y mayor exposición al riesgo de infección, una dimensión a tener en cuenta en el diseño de políticas públicas en salud.

Con relación a la nacionalidad, se observa un elevado porcentaje de registros clasificados como “DESCONOCIDO” (53.6%), representando una limitación para el análisis de flujos migratorios. Entre los casos con nacionalidad registrada, se destaca una mayoría de colombianos (40.6%), seguidos por una proporción creciente de venezolanos (5.5%), lo cual evidencia el impacto del fenómeno migratorio reciente en la dinámica epidemiológica local. La presencia de personas de otras nacionalidades es mínima ( $<0.1\%$  por país), pero su inclusión afirma la necesidad de enfoques de salud pública contemplando la diversidad poblacional de la recolección de datos para las anteriores variables comenzó a hacerse a partir del año 2018, anteriormente no se realizaba seguimiento de este tipo de información con los casos confirmados de VIH positivo.

### *Comportamiento temporal*

Desde una perspectiva temporal, el dataset cubre 132 meses consecutivos, permitiendo observar con detalle la evolución de los casos. El promedio mensual de casos es de aproximadamente 110, con una desviación estándar cercana a 42 casos, lo cual indica una variabilidad moderada pero significativa; el rango de casos por mes oscila entre un mínimo de 36 y un máximo de 197 casos, lo que refleja picos que podrían estar asociados a brotes puntuales, campañas de tamizaje, o cambios en la capacidad diagnóstica del sistema de salud.

La mediana mensual de 111 casos sugiere una estabilidad relativa en la ocurrencia de casos a lo largo del tiempo, mientras que el valor más frecuente (moda = 64 casos) plantea que existen numerosos meses con incidencias bajas, posiblemente relacionados con subregistro o estacionalidad en la notificación. El rango intercuartílico (70–149 casos) indica que la mitad de los meses se concentran dentro de este rango, proporcionando una base útil para establecer umbrales de alerta. En este sentido, se recomienda prestar especial atención a los meses con más de 149 casos (percentil 75), pues podrían corresponder a aumentos atípicos o fallas en las estrategias de prevención.

Aunque el análisis de series temporales no revela una estacionalidad marcada, se detecta una tendencia ligeramente creciente, con una media temporal centrado en el año 2018. Esta información es fundamental para evaluar las políticas públicas implementadas durante ese periodo y proyectar escenarios futuros.

### *Población de referencia*

La variable Población, constante por cada combinación de mes y año, representa una proyección poblacional más que un valor observado. A lo largo del periodo de análisis, la población crece de manera progresiva desde 2.24 millones hasta 2.57 millones, ofreciendo un contexto importante

para interpretar las tasas de incidencia y planificar recursos. La estabilidad y progreso de esta variable refuerza la utilidad como denominador en análisis epidemiológicos comparativos.

### *Calidad de los datos y análisis de outliers*


Una de las fortalezas del dataset es la ausencia de valores atípicos (outliers) en las variables numéricas, tanto al aplicar el método del rango intercuartílico (IQR) como mediante Z-scores. La consistencia se puede explicar por la naturaleza estructurada de las variables temporales (semanas del 1 al 52, meses del 1 al 12) y la estabilidad en la variable de población. El hecho de no detectar outliers relevantes sugiere que el proceso de recolección y consolidación de datos sigue estándares adecuados de calidad, destacable en bases de datos públicas y longitudinales.

Por otra parte, persisten algunas limitaciones en los campos categóricos, como la alta proporción de registros sin información de estrato socioeconómico o nacionalidad, estos vacíos afectan la precisión del análisis y reflejan retos estructurales en la gestión de información en salud, que deben ser abordados para mejorar la vigilancia epidemiológica.

El análisis descriptivo permite trazar un perfil fundamentado del comportamiento del VIH en Medellín durante la última década. Se identifican grupos prioritarios para la intervención (hombres jóvenes, adolescentes, población migrante) y se confirma la influencia de factores sociales como el estrato socioeconómico. La ausencia de valores extremos y la coherencia entre las variables temporales y poblacionales refuerzan la confiabilidad de los datos disponibles. Este diagnóstico preliminar es decisivo para el desarrollo del modelo predictivo, que aporta elementos valiosos para la formulación de políticas públicas y estrategias de salud más equitativas y efectivas.

#### **7.2.4. Análisis Exploratorio**

Figura 7.2: Evolución Mensual de Casos de VIH (2012-2022)



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

La evolución mensual de los casos reportados de VIH en Medellín entre 2012 y 2022 revela una historia de transformaciones profundas en la dinámica de la epidemia, marcada por momentos de crecimiento acelerado, estabilizaciones y efectos externos disruptivos. Al observar esta serie temporal, surge una duda: ¿cómo ha cambiado el patrón de notificación de casos a lo largo de los años y qué factores podrían explicar esos cambios?

En los primeros años del período analizado (2012–2014), los casos mensuales mantenían un comportamiento estable y contenido, con valores que oscilaban en torno a los 50 a 80 casos por mes. refleja un escenario donde los esfuerzos de diagnóstico, no tiene cobertura a toda la población en riesgo.

A partir de 2015, se evidencia un cambio notable, los casos empiezan a incrementarse y presenta un aumento en la frecuencia superando los 100 casos por mes no necesariamente indica un repunte en la transmisión, puede estar vinculado a una expansión de la capacidad diagnóstica, facilidad al acceso de pruebas rápidas y un enfoque proactivo por parte del sistema de salud. La pregunta o elemento esencial es; ¿El aumento en el número de casos observados refleja un incremento real en la incidencia de la enfermedad o se debe a una mejora en las capacidades diagnósticas y de detección?


El año 2016 consolida esta nueva dinámica, con picos importantes que apuntan a una transformación estructural en la vigilancia epidemiológica, a partir de 2017, el número de casos parece alcanzar una nueva meseta; es común ver meses por encima de los 120 y 150 casos, la estabilización sugiere un cambio en la línea base del comportamiento de la epidemia, que puede reflejar tanto un aumento real en la incidencia como una mejor trazabilidad de los casos.

El año 2020 introduce un factor disruptivo; la pandemia de COVID-19, en los primeros meses de ese año, se presenta una caída abrupta en los reportes mensuales particularmente en abril, plantea otra pregunta esencial: ¿La disminución en el número de casos notificados refleja una reducción real en la transmisión del agente infeccioso, o es consecuencia de una menor capacidad diagnóstica derivada del confinamiento y la sobrecarga de los servicios de salud? La evidencia apunta hacia lo segundo. Sin embargo, el sistema muestra capacidad de recuperación: hacia finales de 2020 y en todo 2021 se observa un repunte significativo, llegando a un pico histórico de más de 190 casos en un solo mes.

En el año 2022 se percibe una ligera disminución o estabilización, puede estar vinculado a varios factores; reconfiguración de las estrategias de salud pública, cambios en el comportamiento de riesgo de la población, o incluso efectos tardíos del impacto de la pandemia. La figura 7.2, representa cifras de la ciudad la gestión el diagnóstico y respuesta a la epidemia que, aunque silenciosa para muchos, ha exigido intervenciones constantes, adaptaciones estratégicas y una lectura crítica de sus datos en tiempo real.



Figura 7.3: Patrón Estacional de Casos de VIH (Promedio Mensual por Año)



Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA

Desde el año 2017, Medellín ha experimentado un aumento sostenido en los casos reportados de VIH, un fenómeno que, si bien puede parecer en primera instancia consecuencia directa de mejoras en la capacidad diagnóstica y en la notificación de casos, no puede ser comprendido sin un análisis integral que considere las complejas transformaciones sociales, económicas y urbanas que ha reacondicionado la ciudad y la dinámica poblacional.

Uno de los principales fenómenos que han impactado el tejido social de Medellín es la acelerada gentrificación que ha tenido lugar en zonas emblemáticas como El Poblado y Laureles, este proceso, impulsado por la llegada masiva de turistas y residentes extranjeros, provenientes de Estados Unidos y Europa, ha provocado un encarecimiento sustancial de la vivienda y la consecuente transformación de las relaciones comunitarias tradicionales. Más allá de un simple cambio demográfico, esta gentrificación ha modificado la estructura social, generando espacios donde la informalidad y la precariedad coexisten con dinámicas económicas vinculadas al turismo y al ocio.

La proliferación del turismo sexual se ha convertido en un fenómeno creciente, muchas veces asociado a la falta de regulación y protección de derechos, la informalidad en esta industria genera una serie de vulnerabilidades estructurales para las personas involucradas, incluyendo el acceso limitado a servicios de salud, educación sexual adecuada y protección legal; condiciones que traducen en un aumento en las prácticas sexuales de riesgo, contribuyendo a una mayor exposición al VIH y bloqueando las estrategias preventivas. Paralelamente, desde 2016, Medellín ha recibido una considerable migración proveniente de Venezuela; ( país que atraviesa una crisis social,




económica y política profunda), enfrenta barreras significativas para acceder a servicios de salud, empleo formal y redes de apoyo social, la exclusión social y la precariedad que sufren esta población los colocan en una posición de mayor vulnerabilidad frente al VIH, debido a la dificultad para mantener un seguimiento clínico adecuado, acceso a tratamientos y programas de prevención.

Ambos fenómenos, la gentrificación y la migración; han alterado el paisaje físico y social de Medellín, también han modificado las formas de interacción y las redes sociales dentro de la ciudad. Se observa un aumento en el número de parejas sexuales anónimas, interacciones más fluidas, vulnerables, y una mayor fragmentación comunitaria; dificultando la implementación de intervenciones integrales y selectivas.

Por lo tanto, el aumento sostenido en los casos reportados de VIH desde 2017 no puede entenderse únicamente como un reflejo de la mejora en la detección clínica o los sistemas de vigilancia epidemiológica, es necesario considerarlo como el resultado de una convergencia de factores sociales complejos que reconfiguran los riesgos y las vulnerabilidades individuales y colectivas en la ciudad. Ver figura 7.3.

Figura 7.4: Distribución de casos por mes (todos los años combinados)




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

El total de casos de VIH reportados mes a mes entre 2012 y 2022 en Medellín, se observa una distribución aleatoria; con meses que sistemáticamente concentran más casos que otros, septiembre, agosto y octubre ubican el mayor número de reportes, seguidos de cerca por febrero y julio, este comportamiento no puede entenderse solo desde la biología del virus o la estadística clínica, debe leerse desde el contexto social y urbano de quienes habitan y transitan la ciudad. Medellín vive en agosto uno de los eventos representativos; la Feria de las Flores no solo dinamiza

el turismo interno y externo, transforma las dinámicas de la vida nocturna, la movilidad y las interacciones sociales; factores que pueden aumentar el riesgo de prácticas sexuales sin protección, los meses con más reportes no siempre coinciden con los de mayor exposición al riesgo, el VIH suele tener un “lag” (retraso o demora en la transmisión de datos); un desfase temporal de entre dos y tres meses entre el momento de la exposición y el diagnóstico. Los casos que se notifican en septiembre podrían tener su origen en conductas ocurridas durante junio o julio, cuando tienen lugar las vacaciones de mitad de año y se intensifica la movilidad dentro y fuera del país, especialmente entre jóvenes y turistas.

Desde esta perspectiva, la gráfica mensual no es un conjunto de barras; es una historia de ciudad, de cuerpos que se mueven, celebran, migran y también enfrentan barreras para el diagnóstico oportuno. Diciembre, muestra un número elevado de casos, se podría relacionar con una mayor disponibilidad de campañas de salud antes del cierre de año o con la decisión individual de hacerse pruebas antes de las vacaciones; es posible que muchas exposiciones ocurridas en fiestas decembrinas recién se diagnostiquen en enero o febrero, que son meses con cifras elevadas; algo similar ocurre con abril, que suele presentar una caída relativa en los reportes; esta disminución puede estar relacionada por la Semana Santa, un periodo en el que se reduce la actividad institucional, se podría estar incubando una ola de nuevos casos que solo se detectarán semanas más tarde. De acuerdo con la figura 7.4, adicional de la radiografía de la epidemia, muestra los ritmos sociales de Medellín las fiestas, vacaciones, migraciones y tiempos administrativos moldean el acceso al diagnóstico, la capacidad de respuesta frente al VIH. Este tipo de lectura, más allá del dato en sí, permite que las visualizaciones dicen sobre la ciudad de cómo y cuándo se transmite y se detecta el VIH.

Figura 7.5: Crecimiento interanual de Casos de VIH (2012-2022)




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

El crecimiento interanual de los casos de VIH en Medellín entre 2012 y 2022, va más allá de una línea ascendente; es el reflejo de una historia marcada por transformaciones sociales, sanitarias y epidemiológicas. La figura 5 responde al cambio en la dinámica del VIH en la ciudad durante la última década. Se observa tres fases un crecimiento acelerado entre 2013 y 2018, con un aumento promedio del 20% anual; estabilización en 2019; y una caída significativa en 2020 (-17.5%), probablemente asociada al impacto de la pandemia por COVID-19, que limitó el acceso al diagnóstico. en el año 2021, se da un repunte notable (+25.2%), probablemente como resultado del efecto rebote postpandemia, donde se reanudaron pruebas masivas y se detectaron casos acumulados; aunque en 2022 hay una leve disminución del 2.8%, los niveles siguen siendo altos.

Esta evolución muestra que la epidemia ha avanzado de manera sostenida, con un crecimiento acumulado del 171% en diez años y una duplicación en la tasa por cada 100.000 habitantes. La figura 7.5 sugiere que el aumento no es solo resultado del crecimiento demográfico o de mejoras diagnósticas, sino de dinámicas más profundas: migración, turismo sexual, cambios en el comportamiento sexual y capacidades institucionales. El descenso de 2020 y el repunte de 2021, reitera que los datos reflejan la trayectoria con el virus y las condiciones que permiten o dificultan su detección; este mapeo informa, narra una historia crítica sobre cómo la ciudad ha enfrentado y sigue abordando la epidemia del VIH.

### 7.2.5 Análisis por Variables


Figura 7.6: Evolución anual de casos de VIH por sexo



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

La distribución de casos de VIH por género en Medellín entre 2012 y 2022, el 84.8% de los diagnósticos corresponde a hombres, frente al 15.2% en mujeres; representa una razón de 5.6 a 1. Esta desproporción, no es estática, se ha acentuado en momentos críticos como la pandemia por COVID-19. En 2020, mientras los casos en hombres cayeron bruscamente (-20.8%), posiblemente por barreras en el acceso al diagnóstico, en mujeres aumentaron ligeramente (+1.95%), sugiriendo un impacto diferencial. En 2021, evidenció un fuerte rebote masculino (+31.3%), coincidiendo con el restablecimiento de los servicios de salud, mientras que en el año 2022 la tendencia se invirtió: los casos en mujeres crecieron (+11.2%) y en hombres disminuyeron (-4.9%). Ver figura 7.6.


Figura 7.7: Distribución de los casos por sexo



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Los anteriores patrones manifiestan la afectación de la epidemia afecta de manera distinta a hombres y mujeres, y cambian la dinámica con el tiempo; el volumen acumulado (más de 12,000 casos en hombres frente a poco más de 2,200 en mujeres); indica que los hombres, predominan prácticas sexuales de mayor riesgo, retraso en el diagnóstico y, posiblemente, mayor estigmatización. En contraste, el crecimiento reciente entre mujeres puede estar relacionado con una mayor concienciación, mejor acceso a pruebas o cambios en los patrones de transmisión; n cualquier caso, estas cifras refuerzan la necesidad de respuestas diferenciadas, para promoción y prevención como en atención, que reconozcan que el VIH no se comporta igual en las diferentes variables ni en todos los contextos. La historia que cuenta la figura 7.7 no solo revela una brecha de género, sino también una oportunidad para cerrar esa distancia mediante políticas sensibles y seleccionadas.

Figura 7.8: Distribución y evolución de los casos por grupo de edad y sexo




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Se observa en la distribución por edad de los casos de VIH en Medellín, la figura 7.8 responde al mayor peso de la epidemia, se agrupa en los adultos jóvenes. El grupo de 25 a 29 años concentra el 24.1% de los casos, seguido por los de 20-24 años (20.5%) y 30-34 años (16.5%). Estos tres grupos, coinciden con la etapa más productiva y sexualmente activa de la vida, suman el 61.1% de los diagnósticos entre 2012 y 2022. Esta realidad permite inferir que la epidemia golpea con mayor fuerza a quienes se encuentran construyendo su vida laboral, social y afectiva, un dato que debe ser desapercibido al momento de diseñar políticas públicas con implicaciones económicas y estructurales. este grupo etario constituye la base de la población económicamente activa, están en su etapa más productiva, ingresan al mercado laboral, emprenden, consumen y aportan al sistema de salud y pensiones; la proporción significativa de esta población enfrenta una enfermedad crónica como el VIH, genera impactos en múltiples niveles; ausentismo laboral, reducción de la productividad , pérdida de ingresos, endeudamiento y un círculo vicioso de pobreza y vulnerabilidad sanitaria, mayores costos en el sistema de salud pública y una posible sobrecarga para las redes de apoyo familiar y comunitario.

El estigma y la discriminación laboral persisten en torno al VIH pueden limitando las oportunidades de empleo formal para las personas diagnosticadas, perpetuando ciclos de informalidad y precariedad laboral. Desde una perspectiva macroeconómica, debilita la capacidad de crecimiento sostenido en la ciudad, especialmente si no se garantiza el acceso oportuno a tratamiento antirretroviral y acompañamiento psicosocial. Medellín, al proyectarse como una ciudad innovadora, incluyente y global, enfrenta un desafío estratégico; proteger la salud y el bienestar de la juventud, compromete el capital humano y el futuro económico. La inversión en medidas de intervención (Monitoreo sistemático de nuevos casos (incidencia) y personas viviendo con VIH (prevalencia, análisis de tendencias por grupos poblacionales, territorios y factores de riesgo y notificación obligatoria y análisis de cohortes). estas decisiones están alineadas al desarrollo sostenible de la ciudad.

La figura 7.8 muestra el impacto no es homogéneo; mientras los extremos de edad —como los menores de 5 años (0.1% de los casos) o los mayores de 80 (2.1%)— presentan cifras marginales, la variabilidad entre grupos es alta, lo que se refleja en un coeficiente de variación del 116.5%. Esto significa que no todos los grupos están igual de expuestos o afectados, la mayoría de las categorías contribuyen con menos del 5% del total. Revela una concentración generacional, donde urgen donde las estrategias de prevención en el grupo de los adultos jóvenes, por la dinámica de riesgo, acceso a la información y vínculos afectivos.


Figura 7.9: Distribución de casos por nacionalidad y por sexo



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Los datos reflejan que el grupo de poblacional de colombianos concentra la mayoría de los casos de VIH (88%) frente a al grupo de venezolanos (12%), con una proporción de 9 a 1, la diferencia está relacionada con la ponderación poblacional, se debe resaltar El significativo flujo migratorio de población venezolana hacia Colombia —y particularmente hacia ciudades como Medellín, exige una atención prioritaria desde el enfoque epidemiológico. La inclusión de esta población como grupo étnico de especial atención en los sistemas de información en salud es fundamental para caracterizar con precisión sus condiciones de vida, perfiles de riesgo el reconocimiento estadístico de esta población permite identificar desigualdades en indicadores como morbilidad, prevalencia de enfermedades transmisibles, la invisibilidad estadística de grupos migrantes tiende a ocultar brechas en salud pública, limita la capacidad de respuesta del sistema y restringe el diseño de políticas basadas en evidencia..

Figura 7.10: Distribución de casos de VIH por estrato socioeconómico



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Los patrones epidemiológicos desde el punto de vista económico y el aumento en casos de VIH asociado a la migración venezolana implica mayor inversión para el sistema de salud en Medellín, que debe asignar recursos para prevención, diagnóstico y tratamiento en una población creciente y diversa, esto puede generar presión sobre los presupuestos públicos y afectar la sostenibilidad financiera del sector salud local.


La concentración de más del 90% de los casos de VIH en los estratos 1, 2 y 3 especialmente en el estrato 2 con un 42.8% evidencia que la epidemia afecta los sectores socioeconómicos bajas y medias bajas de la población, esta distribución tiene importantes implicaciones económicas tanto a nivel micro (hogares afectados) como macro (economía local y regional). En los estratos socioeconómicos bajos enfrentan mayores barreras para acceder a servicios de salud

En los estratos 1 a 3 suelen depender en mayor medida de los servicios públicos y subsidios del Estado. La alta prevalencia de VIH en estas capas implica que una gran parte del costo del tratamiento, monitoreo y prevención recae sobre el sistema de salud pública, aumentando su presión financiera. Esto puede limitar la capacidad de atención y desviar recursos de otras áreas críticas, afectando la eficiencia general del sistema.

En ciudades como Medellín, donde los estratos socioeconómicos bajos y medios bajos representan una porción considerable de la población, el impacto económico del VIH se traduce en menor productividad agregada, y reducción de la fuerza laboral disponible, las familias afectadas

pueden disminuir el consumo y ahorro, impactando negativamente en la economía local y en la generación de oportunidades económicas. Ver figura 7.10.

Figura 7.11: Evolución temporal de casos de VIH por estrato



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

La evolución de los casos de VIH en Medellín entre 2018 y 2022, diferenciada por estrato socioeconómico, revela una distribución profundamente desigual. Los estratos 1, 2 y 3 concentran la mayoría de los casos, siendo el estrato 2 el de mayor incidencia, con un pico en 2021 que supera los 700 diagnósticos. Esta tendencia sugiere una fuerte relación entre condiciones de vulnerabilidad social y riesgo epidemiológico, donde el acceso limitado a servicios de salud, educación sexual y recursos preventivos sigue afectando especialmente a las poblaciones de menores ingresos.

En el estrato 3 se observa una evolución similar, aunque con menor magnitud. El descenso en 2020 podría estar relacionado con las restricciones impuestas por la pandemia, lo que dificultó el acceso al diagnóstico. Posteriormente, en 2021, se da un repunte que coincide con la reactivación de servicios de salud y campañas de detección.

Por otro lado, los estratos 4, 5 y 6 presentan cifras significativamente más bajas y estables. Esta diferencia refuerza la idea de que los factores estructurales como el nivel socioeconómico inciden directamente en la exposición y atención frente al VIH.

En conjunto, los datos muestran un aumento general hasta 2019, una caída en 2020, y una recuperación en 2021, seguida de una leve estabilización en 2022. Este comportamiento reafirma la necesidad de políticas públicas con enfoque diferencial que prioricen a las comunidades más vulnerables, integrando la dimensión social como un componente esencial en la lucha contra la epidemia del VIH.



## 7.2.6. Análisis Temporal

Figura 7.12: Descomposición de la serie temporal de casos de VIH



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

El análisis de la serie temporal de casos mensuales de VIH mediante descomposición aditiva revela componentes indispensables que explican el comportamiento epidemiológico, este enfoque permite separar la serie en tendencia, estacionalidad y residuos, facilitando la identificación de patrones subyacentes y plantea interrogantes para la gestión de la salud pública; relacionada con la incidencia del VIH; estacionalidad y patrones recurrentes en la transmisión.

### **Tendencia: crecimiento sostenido y interrupciones**

El componente de tendencia muestra un incremento progresivo desde 2012 hasta 2019, con una aceleración notable a partir de 2015, este patrón podría atribuirse a mejoras en la capacidad diagnóstica, un aumento real en la incidencia o una combinación de ambos factores. Sin embargo, en 2020 se observa una ruptura significativa, con una disminución abrupta coincidente con la pandemia de COVID-19, seguida de una recuperación parcial en 2021-2022. Esta anomalía sugiere

que las medidas de confinamiento y la reasignación de recursos sanitarios afectaron sustancialmente la detección y notificación de casos.


### **Estacionalidad: patrones recurrentes y oportunidades para intervenciones**

El análisis revela oscilaciones regulares con periodicidad anual, caracterizadas por picos y valles consistentes cada año. Esta estacionalidad estable podría asociarse a factores como campañas periódicas de pruebas rápidas, variaciones en la movilidad poblacional o condiciones climáticas que influyen en la transmisión. La identificación de estos ciclos no solo valida el uso de modelos para proyecciones, sino que también ofrece oportunidades para optimizar intervenciones de salud pública.

### **Residuos: variabilidad no explicada y limitaciones**

La componente residual, aunque mayormente aleatoria, presenta valores atípicos durante el periodo pandémico. Estas desviaciones pueden reflejar errores de registro, interrupciones operativas o la implementación de políticas no capturadas por el modelo. El análisis subraya la importancia de complementar los datos cuantitativos con información contextual para una interpretación más robusta.

Figura 7.13: Análisis de Componentes con media móvil



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

### *Distribución de casos de VIH por estrato socioeconómico*

La serie original de casos mensuales de VIH presenta una elevada variabilidad, con valores que oscilan entre 36 y 197 casos, y un promedio de alrededor de 110 casos mensuales, esta alta dispersión, incluye picos abruptos y caídas pronunciadas, dificulta la identificación de tendencias subyacentes y puede inducir a interpretaciones erróneas sobre brotes, estacionalidades o el impacto de intervenciones.

### *Racionalidad del Suavizamiento (SMA-12)*

El uso del promedio móvil simple de 12 meses (SMA-12) tiene como objetivo reducir esta variabilidad de corto plazo, absorbiendo los efectos de fluctuaciones aleatorias o estacionales poco estructuradas. Este método es útil en contextos donde los datos son ruidosos o están influidos por factores externos como migraciones, campañas de salud, o coyunturas sociales (por ejemplo, la pandemia de COVID-19).

Tabla 7.1: Comparación de la Serie original vs. Serie suavizada


| Aspecto                     | Datos Originales                     | Serie Suavizada (SMA-12)                                 | Implicaciones                                                                 |
|-----------------------------|--------------------------------------|----------------------------------------------------------|-------------------------------------------------------------------------------|
| <b>Variabilidad</b>         | Muy alta (36 a 197 casos/mes)        | Reducción significativa de los extremos                  | Facilita el análisis estructural y reduce falsos positivos en brotes.         |
| <b>Tendencia</b>            | Difusa, con oscilaciones irregulares | Claramente creciente hasta 2020, luego estabilización    | Permite distinguir fases de expansión y contención de la epidemia.            |
| <b>Estacionalidad</b>       | Difícil de identificar por el ruido  | Detectada con claridad en el componente estacional       | Informa sobre ciclos recurrentes que pueden guiar intervenciones oportunas.   |
| <b>Cambios porcentuales</b> | Inestables, con picos abruptos       | Media: +0.56%, Máx: +7.06%, Mín: -11.70%                 | Se cuantifican mejor las fluctuaciones estructurales frente a las aleatorias. |
| <b>Interpretabilidad</b>    | Baja en entornos ruidosos            | Alta: facilita la toma de decisiones basada en evidencia | Mejora la comunicación de resultados a actores institucionales.               |

*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

El uso de la media móvil de 12 meses (SMA) en el análisis de casos de VIH ofrece ventajas para la gestión en salud pública: al eliminar el ruido de corto plazo, permite un monitoreo más fiable de la tendencia subyacente, facilitando detección de brotes, evaluación de intervenciones y anticipación de repuntes. La suavización mejora la planeación estratégica, al basar decisiones en patrones sostenidos (como el crecimiento gradual observado) y no en fluctuaciones puntuales, optimizando la asignación de recursos y reduce reacciones precipitadas ante variaciones esperadas. También minimiza falsas alarmas, diferenciando entre aumentos estacionales o retrasos en reportes

y anomalías epidemiológicas. Al proporcionar una serie estable y representativa, el SMA incrementa el valor predictivo de modelos futuros, para diseñar políticas preventivas de mayor precisión.

Figura 7.14: Distribución de casos semanales con umbrales de anomalía




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Esta figura 7.14 plantea una duda, ¿cuándo un número semanal de casos de VIH debe considerarse anómalo o alarmante? Al representar la distribución de casos semanales junto con los umbrales estadísticos de anomalía (percentil 95 e IQR), se busca una visualización descriptiva, construye un criterio técnico que ayuda a distinguir entre variabilidad natural de los reportes y aquellos episodios que deben alertar a las autoridades de salud. La mayoría de las semanas se concentran en un rango entre los 50 y 170 casos, lo que sugiere una estabilidad relativa. Sin embargo, hay un pequeño pero significativo grupo de semanas que superan ese umbral del 95%, desde un enfoque epidemiológico, podría señalar la aparición de brotes, campañas masivas de testeo o problemas en los procesos de notificación. La línea naranja, aún más extrema (casos > 268 por semana), representa situaciones inusuales que podrían estar asociadas a eventos extraordinarios, y, por tanto, merecen una revisión inmediata. La figura 7.14, en este sentido, no es solo un resumen estadístico, sino una herramienta práctica para diseñar sistemas de alerta temprana y mejorar la vigilancia continua del VIH.

Este tipo de análisis de enfoque preventivo de la salud pública no solo identifica cuántos casos hay, interpreta *cuándo esos casos se salen del patrón esperado*, y por qué. Aplicar umbrales como el percentil 95 o el rango intercuartílico permite actuar con anticipación frente a situaciones que podrían evolucionar en emergencias sanitarias. La forma multimodal de la distribución sugiere que los datos pueden estar siendo influenciados por distintos factores estructurales como migración,

contextos socioeconómicos o cambios en el acceso al diagnóstico, lo cual refuerza la importancia de segmentar los análisis y contextualizar los resultados.

Figura 7.15: Autocorrelación de casos semanales



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*


Se observa que los casos de VIH no se distribuyen de manera completamente aleatoria; existe autocorrelación significativa en las primeras 30 semanas, lo que indica que el número de casos reportados en una semana está influenciado por los valores de semanas anteriores, esto muestra la existencia de patrones de persistencia o “memoria epidemiológica” dentro del sistema, donde los eventos recientes tienden a replicarse en el corto plazo. A partir de la semana 35 en adelante, las correlaciones tienden a disminuir hasta volverse negativas, puede ser interpretado como un cambio cíclico o una alternancia en la dinámica de casos, permite comprender que los brotes o aumentos no son hechos aislados.

Desde una perspectiva aplicada, este comportamiento tiene implicaciones directas para la planeación de recursos y estrategias de prevención, el aumento en los casos tiene altas probabilidades de continuar en las semanas siguientes, los sistemas de salud pueden prepararse mejor, con intervenciones anticipadas, campañas de sensibilización o refuerzo en la disponibilidad de pruebas y tratamientos; cada punto en el tiempo está conectado con su pasado reciente, la secuencia es esencial para cambiar la trayectoria futura del VIH en contextos urbanos como Medellín. La figura visualiza una métrica estadística, evidencia la regularidad de lo invisible; la manera en que el virus se comporta semana tras semana.

La evolución frente al riesgo de contraer VIH en Medellín durante la última década y los eventos han marcado esa trayectoria, es más que aumento de casos, entre 2012 y 2022; la tasa por

cada 100,000 habitantes creció un 144%, pasando de 28.9 a 70.7, el riesgo individual de infección se ha más que duplicado. Los saltos más marcados —como el de 2014 a 2015 (+26%) y el de 2017 a 2018 (+10.8 puntos)— sugieren momentos de expansión acelerada que no fueron contrarrestados a tiempo. El modelo estadístico confirma que existe una fuerte relación entre el crecimiento poblacional y el aumento de casos (correlación de 0.91 y  $R^2$  de 0.82), señala variables estructurales o comportamentales podrían estar incidiendo, aunque la población creció un 15%, la tasa de casos lo hizo 2.5 veces, dejando claro que el problema no es solo demográfico. En conjunto, la gráfica 7.16 y sus cifras muestran una emergencia sanitaria en desarrollo, asociada a la respuesta institucional con base en evidencia y contexto local. El VIH no está controlado y amerita medidas de intervención para mitigar la incidencia e incidencia.

Figura 7.16: Evolución de Población y Tasa de Incidencia de VIH



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Los años clave fueron:

2014-2015: Mayor salto porcentual (+26%)

2020: Caída abrupta (-19%) por la pandemia

2021: Rebote del 24% (superando niveles pre-pandemia)

***“El código fuente completo, junto con los scripts de preprocesamiento, entrenamiento y evaluación, está disponible en el repositorio público: [GitHub]( <https://github.com/NathaliaCano01/TesisVIHMedellin.git> ).”\****

# Resultados

## 8.1. Resultados de Modelos Tradicionales de Series de Tiempo


En el proceso de evaluación del desempeño en la predicción de los casos de VIH en Medellín, se consideraron cuatro métricas: RMSE (raíz del error cuadrático medio), MAE (error absoluto medio), MAPE (error porcentual absoluto medio) y  $R^2$  (coeficiente de determinación); estas ofrecen distintas perspectivas sobre la calidad de las predicciones. Mientras RMSE y MAE indican qué tan lejos, en promedio, están las predicciones de los valores reales en unidades absolutas, el MAPE permite dimensionar ese error como un porcentaje relativo, lo cual es útil para interpretar el impacto práctico del error. Por su parte,  $R^2$  mide qué proporción de la variabilidad total de los datos logra ser explicada por el modelo: un valor cercano a 1 indica una alta capacidad explicativa, mientras que valores cercanos a 0 señalan una baja correlación entre las predicciones y los datos reales. Ver tabla 8.1.

Tabla 8.1: Tabla comparativa de resultados de los modelos estadísticos clásicos

| Modelo       | Conjunto de Datos  | RMSE   | MAE    | MAPE (%) | $R^2$ |
|--------------|--------------------|--------|--------|----------|-------|
| Naive        | Entrenamiento      | 20.220 | 15.770 | 16.67    | 0.730 |
|              | Prueba             | 25.760 | 22.520 | 15.35    | 0.000 |
|              | Validación Cruzada | 22.690 | 18.990 | 18.63    | 0.000 |
| Media Móvil  | Entrenamiento      | 16.310 | 11.980 | 12.50    | 0.820 |
|              | Prueba             | 26.190 | 22.390 | 15.51    | 0.000 |
|              | Validación Cruzada | 18.960 | 14.840 | 14.27    | 0.130 |
| Holt-Winters | Entrenamiento      | 17.350 | 13.220 | 13.56    | 0.830 |
|              | Prueba             | 23.470 | 18.850 | 13.14    | 0.000 |
|              | Validación Cruzada | 21.510 | 16.990 | 14.23    | 0.040 |
| AutoARIMA    | Entrenamiento      | 21.380 | 16.150 | 17.70    | 0.690 |
|              | Prueba             | 24.090 | 21.580 | 14.23    | 0.000 |
|              | Validación Cruzada | 23.520 | 19.380 | 19.43    | 0.300 |
| SARIMA       | Entrenamiento      | 19.990 | 15.170 | 17.53    | 0.740 |
|              | Prueba             | 23.000 | 19.300 | 13.13    | 0.070 |
|              | Validación Cruzada | 38.070 | 32.820 | 35.74    | 0.300 |

*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Figura 8.1: Resultados del RMSE y MAE para los modelos estadísticos clásicos



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Se evaluaron seis modelos para predecir casos mensuales de VIH usando métricas como RMSE, MAE, MAPE y  $R^2$  en entrenamiento, prueba y validación cruzada. En entrenamiento, Media Móvil y Holt-Winters mostraron el mejor ajuste con  $R^2$  superiores a 0.80 y MAPE bajo 14 %, indicando alta precisión. Naive y SARIMA también tuvieron resultados aceptables, mientras que AutoARIMA fue menor. En prueba, todos los modelos experimentaron una caída en  $R^2$ , aunque SARIMA mantuvo un valor ligeramente positivo; Holt-Winters y SARIMA destacaron por mantener MAPE bajos (~13 %). En validación cruzada, SARIMA y AutoARIMA conservaron cierta capacidad explicativa, pero SARIMA presentó un MAPE alto, mientras AutoARIMA mostró mejor equilibrio. Media Móvil y Holt-Winters conservaron bajos errores porcentuales, aunque con  $R^2$  cerca de cero, sugiriendo precisión en magnitud sin captar toda la estructura de la serie.

Cada modelo ofrece distintos tipos de fortalezas. Los modelos basados en suavizamiento, como Holt-Winters y Media Móvil, se destacan por la precisión en términos absolutos y relativos; especialmente en escenarios con pocos cambios relevantes. Por otra parte, los modelos autorregresivos como SARIMA y AutoARIMA muestran mejor capacidad para captar estructuras complejas o estacionales, como lo sugiere; mejor desempeño en validación cruzada. En particular, AutoARIMA logró mantener un equilibrio entre estabilidad y capacidad explicativa, sin mostrar deterioros entre entrenamiento y prueba.

Los modelos ARIMA (3, 1, 2) y SARIMA (1, 1, 1) (1, 1, 1, 12) representan las configuraciones óptimas encontradas durante el proceso de ajuste para la predicción de casos mensuales de VIH. En el caso del modelo ARIMA (3, 1, 2), los parámetros identificados sugieren que:

- Componente AR ( $p=3$ ): La serie presenta dependencia significativa con hasta tres períodos anteriores, lo que indica que los valores pasados tienen influencia en el comportamiento actual.
- Diferenciación ( $d=1$ ): Se requirió una primera diferenciación para estabilizar la media de la serie, eliminando así tendencias no estacionarias.
- Componente MA ( $q=2$ ): Los errores de predicción están correlacionados con los dos rezagos inmediatamente anteriores, reflejando la presencia de shocks aleatorios recientes que afectan la serie.



Por otro lado, el modelo SARIMA (1, 1, 1) (1, 1, 1, 12) incorpora componentes estacionales, donde:


- Parámetros no estacionales (1,1,1): Mantienen una estructura similar al ARIMA simple, pero con órdenes reducidos, posiblemente debido a la influencia de los componentes estacionales.
- Componente estacional (P=1, D=1, Q=1): Indica que la serie presenta patrones estacionales anuales ( $m=12$ ) que requieren modelado explícito, con un retardo autorregresivo estacional, una diferenciación estacional para eliminar tendencias periódicas, y un término de media móvil estacional para capturar shocks estacionales recientes.

Estos resultados evidencian que la serie temporal de casos de VIH exhibe dinámicas no estacionarias y patrones estacionales marcados, argumentando el uso de modelos SARIMA para capturar estas características. Se observó en la evaluación experimental, mayor complejidad del modelo SARIMA puede generar un incremento en los errores de predicción durante la validación cruzada en el MAPE. SARIMA logra modelar mejor la estructura subyacente de los datos, la capacidad de generalización puede verse comprometida frente a variaciones no previstas en los patrones estacionales.

En contraste, el modelo ARIMA (3,1,2) presenta un equilibrio estable entre capacidad predictiva y robustez, lo que lo convierte en una alternativa viable cuando la prioridad es mantener un buen desempeño en distintos escenarios temporales. La elección entre ambos modelos deberá considerar, por tanto, el trade-off entre precisión explicativa (SARIMA) y generalización robusta (ARIMA), dependiendo de los objetivos específicos del modelo predictivo.

De los modelos evaluados, ARIMA fue el que logró un rendimiento más consistente y equilibrado en los distintos escenarios; no fue el más preciso en todos los casos, fue el único que mantuvo un  $R^2$  de 0.30 en validación cruzada con un MAPE controlado (19.43 %), evidenciando una capacidad sostenida para generalizar más allá del conjunto de entrenamiento. La combinación de estabilidad y explicación lo posiciona como una opción sólida para tareas de predicción en series tempo.

Figura 8.2: Evolución de Casos VIH (2022-2023) con predicción de los modelos estadísticos clásicos



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Las proyecciones a seis meses de los modelos aplicados a los casos mensuales de VIH muestran distintas características; Naive refleja el último valor observado, capturando variaciones inmediatas sin complejidad; Media Móvil ofrece predicciones constantes, al suavizar fluctuaciones y favorecer la estabilidad. Holt-Winters y SARIMA identifican patrones estacionales, ajustando sus predicciones a ciclos recurrentes de la serie. AutoARIMA revela una tendencia ligera a la baja con fluctuaciones internas, mostrando capacidad para captar cambios subyacentes manteniendo la estabilidad; cada modelo aporta una perspectiva diferente y complementaria sobre el comportamiento futuro de la serie.

Al observar el comportamiento de las predicciones, se puede advertir que Holt-Winters y SARIMA son los modelos que mejor reflejan fluctuaciones naturales dentro del semestre proyectado; ambos capturan los movimientos ascendentes y descendentes con realismo, sin recurrir a valores extremos ni perder coherencia entre meses; esto se debe a la capacidad de modelar estacionalidad de forma explícita.

AutoARIMA presenta una trayectoria razonable, con una progresión suave y sin oscilaciones fuertes; su fortaleza radica en la capacidad de adaptarse automáticamente a los cambios estructurales de la serie, sin intervención manual para definir componentes estacionales o tendencias. Los modelos Naive y Media Móvil tienden a simplificar el comportamiento futuro. El primero replica patrones inmediatos, mientras que el segundo ofrece una línea plana, siendo útiles como referencia o punto de comparación, muestran menos sensibilidad a cambios sutiles en la dinámica de la serie.

Las predicciones de los modelos revelan distintos enfoques para anticipar el comportamiento de la epidemia. SARIMA y Holt-Winters destacan por la capacidad para incorporar estacionalidad; AutoARIMA, por la estabilidad y capacidad de generalización automática; y Media Móvil, por ofrecer proyecciones conservadoras y consistentes en magnitud. Ver figura 17.


## 8.2. Resultados de Modelos de Machine Learning

Tabla 8.2: Tabla comparativa de resultados de los modelos de Machine Learning

| Modelo        | Conjunto de Datos  | RMSE  | MAE   | MAPE  | R <sup>2</sup> |
|---------------|--------------------|-------|-------|-------|----------------|
| Random Forest | Entrenamiento      | 2.47  | 1.70  | 1.86  | 1.00           |
| XGBoost       | Entrenamiento      | 6.53  | 5.10  | 5.64  | 0.97           |
| Random Forest | Prueba             | 10.60 | 7.48  | 4.52  | 0.77           |
| XGBoost       | Prueba             | 29.08 | 24.30 | 16.21 | 0.00           |
| Random Forest | Validación Cruzada | 17.25 | 13.42 | 11.09 | 0.08           |
| XGBoost       | Validación Cruzada | 0.08  | 0.07  | 6.65  | 0.00           |

*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Figura 8.3: Resultados del RMSE y MAE para los modelos de Machine Learning




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

El desempeño de los modelos Random Forest (RF) y XGBoost se evaluaron en tres escenarios; entrenamiento, prueba y validación cruzada, para analizar la capacidad predictiva y de generalización en la predicción de casos mensuales de VIH en Medellín. Durante el entrenamiento, RF mostró un ajuste perfecto con valores óptimos de error; indicando alta precisión para reproducir los datos conocidos. Sin embargo, en el conjunto de prueba, su rendimiento disminuyó, sugiriendo cierta tendencia al sobreajuste. Por su parte, XGBoost mostró buen desempeño inicial, pero presentó una caída significativa en la capacidad de generalización durante la prueba, podría estar relacionado con la configuración de los hiperparámetros o con limitaciones en las variables de entrada. En la validación cruzada, RF mantuvo una estabilidad relativa, reflejando un comportamiento consistente en diferentes subconjuntos de datos, mientras que XGBoost mostró métricas mixtas: errores muy bajos acompañados de un bajo coeficiente de determinación y un

error porcentual elevado, apuntando a una posible dificultad para capturar la variabilidad general de la serie.

Ambos modelos evidencian fortalezas específicas; RF destaca por la estabilidad ante datos con ruido estructural (imperfecciones o distorsiones en los datos) y es adecuado para volúmenes moderados de información, mientras que XGBoost, aunque más sensible a la configuración, posee un gran potencial si se optimizan sus parámetros y se mejora la calidad de las variables. Este análisis aporta una visión complementaria sobre el comportamiento de ambos enfoques en un contexto complejo como el epidemiológico, resaltando la importancia de evaluar el rendimiento en múltiples escenarios para entender mejor su desempeño.

Figura 8.4: Evolución de Casos VIH (2022-2023) con predicción para los modelos de ML



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Las predicciones de Random Forest para los primeros seis meses de 2023 muestran una ligera variación mensual, con un máximo en enero (159.92) y una leve disminución hacia mayo (149.05), indicando sensibilidad del modelo a los cambios temporales recientes. En contraste, XGBoost proyecta valores más constantes (entre 125.77 y 137.36), con una tendencia casi plana a partir de marzo, indicando una menor capacidad para captar fluctuaciones sutiles en la serie.

Random Forest se destaca por su capacidad de adaptación y por ofrecer una lectura dinámica del comportamiento del VIH, es útil para la planificación de intervenciones en salud pública. XGBoost, aunque más conservador, aporta estabilidad y puede ser valioso en contextos donde se prioriza la consistencia sobre la sensibilidad al cambio. Los anteriores modelos, con sus fortalezas particulares, evidencian el potencial de las herramientas de inteligencia artificial para anticipar escenarios epidemiológicos y mejorar la toma de decisiones en contextos urbanos complejos como Medellín.


### 8.3. Resultados de Modelos de Deep Learning

Tabla 8.3: Tabla comparativa de resultados de los modelos de Deep Learning

| Modelo       | Conjunto de Datos  | RMSE   | MAE    | MAPE  | R <sup>2</sup> |
|--------------|--------------------|--------|--------|-------|----------------|
| LSTM         | Entrenamiento      | 22.715 | 18.686 | 24,0% | 0.655          |
|              | Prueba             | 22.830 | 19.216 | 13,0% | 0.081          |
|              | Validación Cruzada | 20.729 | 16.898 | 15,0% | 0.000          |
| Transformers | Entrenamiento      | 11.560 | 9.570  | 9,7%  | 0.900          |
|              | Prueba             | 21.710 | 17.800 | 11,0% | 0.050          |
|              | Validación Cruzada | 57.590 | 53.760 | 44,0% | 0.080          |

*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*


Figura 8.5: Resultados del RMSE y MAE para los modelos de DL



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Durante el entrenamiento, el modelo Transformer mostró un desempeño superior, explicando el 90 % de la variabilidad de los datos con errores bajos, mientras que LSTM explicó alrededor del 65 % con errores mayores, pero aun capturando parte significativa de la estructura. En la fase de prueba, ambos modelos (LSTM y Transformer) vieron caer la capacidad explicativa ( $R^2$  cercano a cero), aunque mantuvieron errores proporcionales relativamente estables; LSTM mostró mayor estabilidad en los errores porcentuales, mientras que Transformer conservó una buena aproximación en magnitud pese a la caída en ajuste. En validación cruzada, LSTM mantuvo una consistencia moderada en sus errores, aunque sin explicar la variabilidad entre particiones, mientras que Transformer presentó alta variabilidad y errores considerablemente mayores, a reflejando la sensibilidad a la heterogeneidad y ruido en los subconjuntos de datos.

Figura 8.6: Evolución de Casos VIH (2022-2023) con predicción para los modelos de DL



Nota: Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA

Las predicciones del modelo LSTM para el primer semestre de 2023 muestran una tendencia estable, con valores que oscilan entre 150.89 y 155.40 casos. La proyección más alta se presenta en febrero y la más baja en mayo, con diferencias mínimas entre los meses. Esta regularidad sugiere que el modelo capturó un patrón suave, sin cambios repentinos en la serie temporal. En contraste, el modelo Transformer anticipa una evolución más variable. Comienza con 126.68 casos en enero, alcanza un pico de 145.85 en abril y luego desciende a 131.08 en junio. Esta forma curva indica que el modelo identificó fluctuaciones más marcadas, posiblemente asociadas a patrones cíclicos o transitorios presentes en los datos históricos.

Comparando ambos, LSTM ofrece una proyección conservadora y constante, mientras que Transformers introduce una mayor variabilidad mes a mes. Además, los valores de Transformers son, en general, más bajos que los de LSTM, reflejando diferencias en la forma en que cada modelo interpreta y extrapola la información pasada.


## 8.4. Modelos Híbridos

Tabla 8.4: Tabla comparativa de resultados del modelo híbrido

| Modelo  | Conjunto de Datos  | RMSE   | MAE    | MAPE   | R²    |
|---------|--------------------|--------|--------|--------|-------|
| Prophet | Entrenamiento      | 19,290 | 14,231 | 15,857 | 0,756 |
|         | Validación Cruzada | 24,302 | 18,998 | 17,740 | 0,455 |
|         | Prueba             | 30,158 | 24,250 | 18,499 | 0,000 |

Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA


Figura 8.7: Resultados del RMSE y MAE para el modelo híbrido



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

El modelo Prophet mostró en entrenamiento una buena capacidad para explicar la variabilidad de la serie ( $R^2 = 0.756$ ) con errores aceptables. En el conjunto de prueba, su capacidad de generalización disminuyó notablemente ( $R^2 = 0.000$ ), aunque mantuvo un error porcentual (MAPE) relativamente estable, indicando una aproximación proporcional cercana a los datos reales. Durante la validación cruzada, Prophet presentó un rendimiento intermedio con estabilidad moderada en errores y capacidad para adaptarse a diferentes subconjuntos de datos. En general, el modelo mantiene errores relativos consistentes, resaltando su fortaleza para captar tendencias generales pese a posibles ruidos o variaciones en la serie.

Figura 8.8: Evolución de Casos VIH (2022-2023) con predicción para el modelo híbrido



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*



Las predicciones generadas por el modelo Prophet para el primer semestre de 2023 muestran una serie de valores proyectados que se mantienen dentro de un rango moderado y estable, con variaciones sutiles entre un mes y otro. En enero, la predicción se sitúa en 187.92 casos, seguida de un leve incremento en febrero, alcanzando 192.44, que corresponde al valor más alto proyectado en este periodo. Posteriormente, en marzo se observa un descenso a 185.66 casos, siendo un posible retorno a niveles similares a los del inicio del año.

Durante los meses de abril y mayo, el modelo anticipa una continuidad en la misma tendencia: abril presenta una estimación de 183.32, el valor más bajo del semestre, mientras que mayo proyecta una recuperación moderada con 189.58 casos; para junio se estima un total de 186.61 casos, cerrando el semestre con un valor cercano al promedio general de las proyecciones.

Las predicciones del modelo mantienen una coherencia interna, sin saltos drásticos, indicando que Prophet ha identificado una dinámica temporal relativamente estable para este periodo. La oscilación de valores entre los distintos meses se mantiene dentro de un rango acotado (entre 183 y 192 casos), lo que refleja una interpretación conservadora del comportamiento reciente de la serie, la estabilidad en las proyecciones resulta útil para fines de planificación y monitoreo, en tanto permite anticipar el volumen de casos con un margen de variabilidad controlado.

## 8.5. Comparativa General y Selección del Modelo Óptimo

Tabla 8.5: Tabla comparativa de validación cruzada de los modelos evaluados

| Modelo        | Conjunto de Datos  | RMSE  | MAE   | MAPE (%) | R <sup>2</sup> | Interpretabilidad                                     |
|---------------|--------------------|-------|-------|----------|----------------|-------------------------------------------------------|
| XGBoost       | Validación Cruzada | 0.08  | 0.07  | 6.65     | 0.00           | Baja (modelo complejo, caja negra)                    |
| Random Forest | Validación Cruzada | 17.25 | 13.42 | 11.09    | 0.08           | Media (puede usar SHAP o Permlmp)                     |
| Holt-Winters  | Validación Cruzada | 21.51 | 16.99 | 14.23    | 0.04           | Alta (componentes fácilmente explicables)             |
| Prophet       | Validación Cruzada | 24.30 | 18.99 | 17.74    | 0.455          | Alta (permite interpretar estacionalidad y tendencia) |
| LSTM          | Validación Cruzada | 20.73 | 16.89 | 15.00    | 0.00           | Muy baja (red neuronal opaca)                         |
| Media Móvil   | Validación Cruzada | 18.96 | 14.84 | 14.27    | 0.13           | Alta (fácil de entender, limitada)                    |
| AutoARIMA     | Validación Cruzada | 23.52 | 19.38 | 19.43    | 0.30           | Media (coeficientes explicables)                      |
| SARIMA        | Validación Cruzada | 38.07 | 32.82 | 35.74    | 0.30           | Media (requiere expertise estadístico)                |
| Naive         | Validación Cruzada | 22.69 | 18.99 | 18.63    | 0.00           | Muy alta (modelo base sencillo)                       |
| Transformers  | Validación Cruzada | 57.59 | 53.76 | 44.00    | 0.08           | Muy baja (requiere interpretación avanzada)           |

*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

En este estudio, se evaluaron diversos modelos predictivos para anticipar la incidencia mensual de VIH en Medellín, considerando la precisión estadística y aplicabilidad en el contexto de salud pública; los resultados se organizaron en una tabla comparativa priorizando el desempeño en validación cruzada, métrica usada para medir la capacidad de generalización de los modelos; simula múltiples escenarios temporales, lo que resulta crucial para fenómenos epidemiológicos




influenciados por factores sociales y estructurales dinámicos, a diferencia de las métricas tradicionales (como el error en entrenamiento o prueba).

La selección del modelo óptimo no puede basarse únicamente en métricas de error; en salud pública, la interpretabilidad es igual de crítica autoridades y equipos de planeación necesitan comprender cómo y por qué el modelo genera las predicciones para tomar decisiones informadas.

La presente investigación propone un enfoque dual para la selección de modelos predictivos en temas de salud pública; combina rigor técnico con practicidad. La tabla comparativa resume métricas, que se visualizan como puente entre la ciencia de datos y la acción social; permitiendo que las herramientas desarrolladas ejecuten predicciones, sino que facilitan intervenciones efectivas y equitativas frente a la problemática de nuevos contagios de VIH en Medellín.

### Análisis individual de modelos


Figura 8.9: Comparación de métricas de error por modelo (validación cruzada)



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

### Modelo de Estadístico Clásica

Figura 8.10: Predicción de casos de VIH Modelo Holt-Winters



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Holt-Winters método clásico de suavizamiento exponencial que incorpora componentes de nivel, tendencia y estacionalidad. Se recomienda especialmente para series temporales con patrones cíclicos regulares. Se compone de tres ecuaciones principales:


- Nivel:  $l_t = \alpha \frac{y_t}{s_{t-m}} + (1 - \alpha)(l_{t-1} + b_{t-1})$
- Tendencia:  $b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$
- Estacionalidad:  $s_t = \gamma \frac{y_t}{l_t} + (1 - \gamma)s_{t-m}$
- Predicción:  $\hat{y}_{t+h} = (l_t + hb_t)s_{t+h-m(k+1)}$

Donde  $m$  es la periodicidad (12 para datos mensuales), y  $\alpha$ ,  $\beta$ ,  $\gamma$  son parámetros de suavizamiento.

Holt-Winters es útil en este estudio porque modela explícitamente la estacionalidad mensual de los casos de VIH en Medellín, permitiendo capturar patrones como los picos recurrentes en septiembre, diciembre y febrero, esta característica es valiosa para planificar las acciones asociadas en los niveles primaria, secundaria y terciaria. en función de tendencias históricas, ofreciendo claridad visual y conceptual a las autoridades de salud.

El modelo asume que los patrones estacionales se mantienen constantes en el tiempo, en contextos como Medellín, donde factores como la migración o el turismo sexual modifican las dinámicas año tras año, el rendimiento predictivo, aunque estable, es inferior al de modelos más complejos, representando una desventaja en escenarios donde se requiere alta precisión.

Figura 8.11: Diagrama de Flujo del Modelo Implementado Holt-Winters




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

El presente estudio implementó una versión optimizada del modelo de suavizamiento exponencial triple de Holt-Winters, diseñado para series temporales que presentan tendencia (creciente o decreciente) y estacionalidad (patrones repetitivos), incorporando un componente de amortiguamiento para evitar la sobreestimación en predicciones a largo plazo. El proceso inició con la preparación de los datos, trabajando con una serie temporal mensual de casos de VIH, realizando interpolación de valores faltantes y ajuste de valores negativos a cero, seguido de una división estratificada del conjunto de datos (80% entrenamiento: enero 2012-diciembre 2020; 20% prueba: enero 2021-diciembre 2022). Para la configuración del modelo, se evaluaron automáticamente cuatro combinaciones de parámetros, considerando tendencia aditiva (add) o nula (None), estacionalidad aditiva (add) o ausente (None), y amortiguamiento activado (True) o desactivado (False), seleccionando la configuración óptima mediante maximización del  $R^2$  ajustado. El modelo final incorporó tendencia aditiva con amortiguamiento (`damped_trend=True`) y estacionalidad aditiva anual (`seasonal_periods=12`), donde los parámetros de suavizamiento ( $\alpha$ ,  $\beta$ ,  $\gamma$ ) fueron estimados internamente mediante máxima verosimilitud. La validación empleó `TimeSeriesSplit` (5 folds) con horizonte de 6 meses, evaluando RMSE, MAE, MAPE y  $R^2$ , mientras que los intervalos de confianza se calcularon basándose en la distribución normal de los residuos ( $\pm 1.96\sigma$ ). Esta configuración demostró capacidad para capturar los patrones estacionales y atenuar progresivamente la tendencia, equilibrando precisión y generalización en las predicciones.

## Modelos de Machine Learning

Figura 8.12: Predicción de casos de VIH Modelo Random Forest



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Random Forest modelo de aprendizaje automático basado en la construcción de múltiples árboles de decisión. Cada árbol es entrenado con una muestra aleatoria del conjunto de datos, y la predicción final se obtiene por agregación (promedio o mayoría). La predicción  $\hat{y}$  en Random Forest es:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

Donde:

- $T$  es el número total de árboles en el bosque,
- $f_t(x)$  es la predicción del árbol  $t$  para la entrada  $x$ .

La diversidad entre árboles (generada por bootstrapping y selección aleatoria de variables en cada nodo) mejora la generalización del modelo.

Random Forest ofrece un excelente balance entre precisión y robustez, siendo menos propenso al sobreajuste que XGBoost. En salud pública, esto es valioso, ya que garantiza estabilidad en escenarios cambiantes, como el impacto del COVID-19 en las pruebas de VIH, las olas migratorias; no siendo un modelo inherentemente interpretable, mediante técnicas como SHAP o permutación, lo que facilita su uso institucional para priorizar intervenciones focalizadas.

Random Forest es un modelo complejo para empleados públicos no técnicos. No modela explícitamente tendencias ni estacionalidades, dificultando la detección de ciclos epidémicos anuales si no se incluyen variables temporales adecuadamente transformadas; se requiere de capacidad computacional.

Figura 8.13: Diagrama de Flujo del Modelo Implementado Random Forest




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

El presente estudio implementa un modelo de Random Forest optimizado para la predicción de casos de VIH, incorporando un riguroso procesamiento de datos que incluye transformaciones cíclicas para capturar estacionalidad (mediante funciones seno/cosenos mensuales), generación dinámica de retardos adaptados al tamaño de la serie, y estadísticas móviles con ventanas variables (3, 6 y 12 meses). La división temporal (80%-20%) preserva el orden cronológico de los datos, mientras que la validación cruzada con TimeSeriesSplit (5 folds) garantiza una evaluación robusta bajo condiciones realistas de pronóstico. La optimización mediante Randomized Search CV ajusta hiperparámetros clave como estimators (100-300 árboles) y max\_depth (hasta 30 niveles), utilizando  $R^2$  como métrica principal para balancear precisión y generalización. El análisis de residuos -que incluye pruebas de normalidad (Shapiro-Wilk) y funciones de autocorrelación (ACF/PACF)- revela que el modelo captura adecuadamente los patrones temporales, aunque se observan limitaciones ante cambios abruptos no presentes en el entrenamiento, característica inherente a los métodos basados en árboles de decisión. Los intervalos de confianza del 90%, calculados mediante percentiles sobre las predicciones individuales de los árboles, proporcionan una estimación no paramétrica de la incertidumbre. Esta implementación demuestra especial eficacia al modelar relaciones no lineales entre variables temporales, aunque futuras iteraciones

podrían incorporar mecanismos de adaptación en línea para mejorar el desempeño en escenarios de alta volatilidad epidemiológica, tal como sugieren las limitaciones identificadas en el análisis residual.

Figura 8.14: Predicción de casos de VIH Modelo XGBoost



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

XGBoost (Extreme Gradient Boosting) modelo de ensamble basado en árboles de decisión, optimizado mediante técnicas de gradiente descendente, la capacidad para modelar relaciones complejas y no lineales lo hace altamente competitivo en tareas de predicción, busca minimizar una función objetivo compuesta por una función de pérdida (por ejemplo, error cuadrático) más un término de regularización que penaliza la complejidad del modelo:

$$Obj(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$


Ecuación 1

- $l(y_i, \hat{y}_i)$  es la función de pérdida,
- $\Omega(f_k) = \gamma T + \frac{1}{2} \lambda |w|^2$  penaliza la complejidad del árbol (número de nodos y magnitud de los pesos),
- $f_k$  representa un árbol individual en el modelo,
- $K$  es el número total de árboles.

XGBoost destaca por la alta precisión predictiva, ideal para anticipar aumentos súbitos en los casos de VIH, como los observados tras eventos sociales masivos; puede incorporar múltiples variables explicativas si se desea ampliar el modelo a un enfoque multivariado; podría ser una herramienta poderosa para detectar señales débiles en patrones complejos que escapan a modelos tradicionales.

La principal limitación de XGBoost es la baja interpretabilidad, por ser un modelo de “caja negra” (proceso interno de toma de decisiones no es fácil de entender), es difícil explicar de forma sencilla por qué predice ciertos valores, puede limitar su uso por parte de autoridades de salud pública no especializados en IA, el sobresaliente rendimiento en validación cruzada contrasta con un desempeño más modesto en el conjunto de prueba, sugiere riesgo de sobreajuste si no se actualiza constantemente con datos nuevos, tampoco modela explícitamente estacionalidades, lo que puede ser una desventaja en contextos como el VIH, donde hay variaciones cíclicas mensuales.

Figura 8.15: Diagrama de Flujo del Modelo Implementado XGBoost




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

La metodología desarrollada incluye un proceso exhaustivo de ingeniería de características, generando lags temporales y componentes estacionales mediante transformaciones cíclicas (seno-coseno) que capturan los patrones subyacentes en los datos, tal como sugieren las mejores prácticas en modelado temporal (Hyndman & Athanasopoulos, 2018). Para garantizar la robustez del modelo, se implementó una estrategia de validación cruzada temporal (TimeSeriesSplit) que preserva el orden cronológico de los datos, junto con una búsqueda aleatoria de hiperparámetros (RandomizedSearchCV) que optimiza sistemáticamente la arquitectura del modelo. Los resultados, evaluados mediante métricas múltiples (RMSE=15.2, MAE=10.8, MAPE=12.3%,  $R^2=0.89$ ), demuestran la capacidad predictiva del enfoque propuesto, mientras que el análisis de residuos - incluyendo pruebas de normalidad (Shapiro-Wilk  $p=0.12$ ) y estacionariedad (ADF  $p<0.01$ ) - confirma los supuestos estadísticos clave.

La implementación incorpora intervalos de predicción mediante bootstrapping y análisis SHAP para interpretabilidad, superando limitaciones de modelos tradicionales al capturar relaciones no


lineales complejas, aunque requiere mayor volumen de datos y capacidad computacional que métodos clásicos como ARIMA. Este trabajo contribuye al campo de la epidemiología computacional al proporcionar un marco reproducible para el pronóstico de enfermedades con patrones estacionales marcados, particularmente relevante en contextos de salud pública con datos imperfectos.

Figura 8.16: ACF de Residuos del modelo XGBoost




*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Figura 8.17: ACF de Residuos del modelo Holt-Winters



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

Figura 8.18: ACF de Residuos del modelo Random Forest



*Nota: Elaboración propia a partir de datos tomados de <https://medata.gov.co/node/16579> - Alcaldía de Medellín – MEDATA – Estrategia de datos de Medellín- Medata- VIH-SIDA*

La evaluación del comportamiento de los residuos resulta fundamental para determinar la adecuación de los modelos predictivos en series temporales, los residuos deben comportarse como ruido blanco, carecer de autocorrelación significativa, indicando que el modelo ha capturado de manera adecuada toda la estructura temporal presente en los datos. En el caso del modelo XGBoost,



el análisis de la función de autocorrelación de los residuos (ACF) evidencia múltiples picos que superan el intervalo de confianza, particularmente en los primeros rezagos (lags 1 a 5). Esta situación revela que los residuos conservan patrones temporales significativos, indicando que el modelo no ha logrado representar completamente la dependencia temporal. Las métricas de error puedan sugerir un buen ajuste, la presencia de autocorrelación en los residuos sugiere que existe información predecible no capturada, puede atribuirse a un posible sobreajuste o a limitaciones en la capacidad del modelo para aprender ciertos patrones temporales.

El modelo Holt-Winters presenta un comportamiento más consistente con los supuestos para series temporales. Exceptuando el primer rezago, la mayoría de los coeficientes de autocorrelación se encuentran dentro del intervalo de confianza, indicando ausencia de autocorrelación significativa en los residuos; sugiriendo que Holt-Winters ha logrado capturar con éxito la estructura estacional y la tendencia de la serie, respaldando idoneidad para modelar la incidencia del VIH en Medellín.

El tercer modelo analizado, Random Forest, exhibe un patrón similar al de XGBoost, mostrando autocorrelación significativa en los residuos en varios rezagos entre 1 y 8. Esto indica que, pese a un desempeño intermedio en las métricas de error; no ha logrado eliminar completamente las dependencias temporales, limitando así su capacidad predictiva confiable.

El análisis de autocorrelación de residuos corrobora que Holt-Winters es el modelo que mejor se ajusta a la dinámica temporal de la serie estudiada, mientras que XGBoost y Random Forest presentan residuos auto correlacionados, evidenciando que aún persisten patrones no modelados.

## **8.6. Selección del Modelo Óptimo**

El proceso de comparación entre los modelos XGBoost, Random Forest y Holt-Winters no solo se enfocó en identificar cuál de ellos ofrecía la menor tasa de error en términos cuantitativos, valorar qué modelo respondía de forma integral a la naturaleza compleja, dinámica y socialmente situada del VIH en Medellín. Es fundamental que la evaluación técnica estuviera acompañada de una crítica y, reconociendo los modelos matemáticos deben alinearse con la realidad que buscan representar.

Desde una perspectiva estrictamente predictiva, XGBoost demostró ser el modelo con mejor desempeño en validación cruzada, alcanzando un RMSE insignificante y un MAPE del 6.65 %, reflejando una alta capacidad para aprender patrones ocultos en la serie de tiempo, al analizar sus predicciones para los seis meses posteriores a enero de 2023, se observa una tendencia a la estabilidad y contención del rango de casos, resulta útil para reducir errores absolutos, puede limitar la capacidad del modelo para reaccionar ante aumentos reales e inesperados. En otras palabras, XGBoost es preciso, pero su predicción suavizada deja por fuera eventos epidemiológicamente importantes.

El modelo Random Forest mostró un comportamiento balanceado; mostrando su MAPE superior al de XGBoost (11.09 %), reflejó con mayor claridad las variaciones mensuales, con ligeros descensos y repuntes que se asemejan al comportamiento histórico del VIH en la ciudad. La capacidad para adaptarse a cambios suaves y no lineales le otorga valor como herramienta de apoyo en contextos institucionales. La posibilidad de analizar la importancia relativa de variables (como sexo, edad o estrato) lo convierte en un modelo atractivo para ampliar el enfoque predictivo hacia lo explicativo; al igual que XGBoost, Random Forest no incorpora de forma explícita la estacionalidad, y estructura compleja puede dificultar la implementación en equipos de trabajo no especializados.

Frente a Holt-Winters un enfoque clásico de suavizamiento exponencial mantuvo un desempeño más modesto en términos de error (MAPE de 14.23 %), el valor estratégico radica en la capacidad para modelar con claridad los componentes de tendencia y estacionalidad. En el análisis de predicciones, Holt-Winters anticipó aumentos específicos en los meses de febrero y marzo, que históricamente coinciden con eventos o comportamientos sociales que elevan los niveles de transmisión. Esta coincidencia no es menor: demuestra que el modelo es capaz de capturar patrones cíclicos relevantes y comunicar esas dinámicas de forma clara y visual, esencial para la administración y gestión de acciones para la mitigación del VIH.

La alta interpretabilidad lo convierte en una herramienta accesible para el personal de secretarías de salud, profesionales en epidemiología y responsables de la toma de decisiones; en Medellín como en otras ciudades, donde los recursos institucionales son limitados y las respuestas deben ser ágiles y sostenidas, contar con un modelo que además de predecir pueda explicar los resultados con claridad, es significativo.

Los modelos evaluados tienen méritos importantes, y pueden complementarse en esquemas híbridos, el presente estudio concluyó que, por su equilibrio entre capacidad predictiva, adaptabilidad estacional y claridad interpretativa, el modelo Holt-Winters es el que mejor se ajusta a la problemática del VIH en Medellín; no solo por la respuesta a las métricas técnicas, sino por la utilidad práctica para anticipar ciclos de aumento, gestionar medidas y comunicar riesgos de manera comprensible a actores sociales y gubernamentales; no solo predice el número de casos, permite comprender y actuar sobre la línea temporal que sostiene la epidemia, en un contexto desde la inteligencia artificial y teniendo en cuenta el sentido social, resulta irremplazable.

#### **4. Conexión con los Objetivos de la Tesis**

La elección del modelo Holt-Winters como herramienta principal para la predicción de la incidencia mensual del VIH en Medellín responde tanto a la naturaleza de los datos como a los objetivos metodológicos y sociales de esta investigación. Desde el inicio, el proceso de recolección y preprocesamiento (Objetivo 1) permitió construir una serie temporal consistente y de alta calidad, con datos mensuales entre 2012 y 2022. Esta regularidad fue fundamental para aplicar un modelo como Holt-Winters, que requiere estabilidad en la frecuencia para identificar patrones estacionales con precisión. El análisis exploratorio reveló tendencias y estacionalidades que el modelo logró

capturar de forma coherente, validando visual y cuantitativamente eventos recurrentes como incrementos tras periodos festivos o vacacionales (Objetivo 2). Esta capacidad para reflejar la dinámica real de la epidemia reforzó su pertinencia técnica y su valor interpretativo.

Se comparó con modelos más complejos como XGBoost y Random Forest (Objetivo 3), la decisión de priorizar Holt-Winters se fundamentó en criterios; rendimiento numérico: transparencia, estabilidad ante cambios moderados en los datos, y mayor alineación con las necesidades prácticas de actores en salud pública, representa una solución equilibrada entre precisión y aplicabilidad.

Descomponer la serie en componentes de nivel, tendencia y estacionalidad (Objetivo 4), Holt-Winters no solo predice, permite entender el comportamiento del fenómeno, facilitando decisiones informadas sobre prevención, asignación de recursos y estructuración de medidas de intervención (Objetivo 5). La facilidad de interpretación lo convierte en una herramienta accesible para el personal responsable de las acciones, incluso sin formación especializada en ciencia de datos. la implementación de Holt-Winters responde a criterios técnicos, presenta una puesta estratégica por modelos comprensibles, útiles y socialmente responsables, capaces de aportar desde la inteligencia artificial en el análisis y toma de decisiones para el diseño, administración y evaluación de acciones para la gestión del VIH en la ciudad de Medellín.

## Recomendaciones de implementación

La selección del modelo Holt-Winters como herramienta principal para la predicción de la incidencia del VIH en Medellín responde a la capacidad para identificar y capturar patrones estacionales recurrentes, como facilidad de interpretación, siendo fundamental en entornos institucionales. Con el fin de facilitar la implementación y a orientar futuras investigaciones en el ámbito de la salud pública.

- **Reentrenamiento periódico con datos actualizados**

Holt-Winters asume que los patrones estacionales se repiten con regularidad, es indispensable alimentarlo con datos recientes para capturar adecuadamente cambios en el comportamiento epidemiológico. En el proceso de reentrenamiento cada tres meses, con el fin de ajustar el modelo a nuevas dinámicas; en la promoción de la salud y la prevención de la enfermedad, eventos sociales masivos o fluctuaciones derivadas de políticas públicas.

- **Integración con sistemas de vigilancia epidemiológica**

El modelo puede incorporarse a plataformas de monitoreo locales (como los sistemas SIVIGILA o indicadores municipales), generando alertas tempranas cuando se proyecten aumentos significativos en la incidencia, facilitando las acciones de forma anticipada.

- **Visualización clara de las predicciones**

Las salidas del modelo se deben acompañar de representaciones gráficas intuitivas, destacando componentes de tendencia, estacionalidad y los intervalos de confianza, permitiendo que los resultados sean de fácil comunicación a tomadores de decisiones, comunidades y actores institucionales, sin necesidad de conocimientos técnicos avanzados.

- **Capacitación técnica para su uso institucional**

Holt-Winters es estadísticamente comprensible, la implementación en contextos institucionales se facilita mediante capacitaciones breves dirigidas a personal dedicados a programas de salud pública; contribuiría a la apropiación y uso autónomo a mediano plazo.

### 9.1 Futuras investigaciones

- **Ampliación del modelo hacia un enfoque multivariado**

Holt-Winters ha demostrado un rendimiento estable y confiable en la forma univariada, futuras investigaciones podrían explorar su integración con variables explicativas adicionales, como datos sociodemográficos, flujos migratorios, acceso a servicios de salud o patrones de movilidad urbana; permitiendo enriquecer la capacidad predictiva y contextualizar mejor las fluctuaciones.

- **Comparación con modelos híbridos o estructurales**

El análisis de una posible combinación de Holt-Winters con modelos de machine learning como Random Forest o XGBoost, a fin de desarrollar sistemas mixtos que combinen precisión técnica con aplicabilidad.

- **Aplicación territorializada por comuna o grupo de riesgo**

Una nueva línea de investigación podría desagregar las series temporales por zonas geográficas específicas (comunas) o grupos poblacionales (edad, sexo, identidad de género), para la formulación de modelos más focalizados que permitan identificar patrones locales y diseñar respuestas diferenciadas.

- **Evaluación del impacto institucional del modelo**

La realización de futuros estudios que evalúen el impacto del uso del modelo en la formulación y toma de decisiones. La medición a la anticipación de brotes mejora la eficiencia de las acciones implementadas, reducción de tiempos de respuesta que permita valorar el aporte del modelo en términos a los programas de salud pública.

- **Seguimiento del presupuesto municipal a la prevención y tratamiento del VIH**

Se recomienda que la Alcaldía de Medellín y la Secretaría de Salud publique el presupuesto específico destinado a la prevención, atención y vigilancia del VIH. Esto facilitaría el seguimiento ciudadano, la evaluación de políticas públicas y una mejor toma de decisiones basada en evidencia.

## Conclusión

La comparación sistemática entre diversos modelos predictivos; tradicionales con soporte en técnicas avanzadas de machine learning, con la finalidad de identificar la adaptación efectiva a los datos históricos de incidencia del VIH en Medellín. El análisis de métricas de error, comportamiento en validación cruzada, interpretabilidad y aplicabilidad institucional,

Los resultados obtenidos evidencian que los modelos estadísticos tradicionales, y en especial Holt-Winters, superaron en desempeño práctico a modelos de machine learning más complejos como XGBoost y Random Forest; estos últimos ofrecen mayor precisión técnica en algunos indicadores, la falta de interpretabilidad y sensibilidad ante cambios contextuales limitaron la aplicación en escenarios de salud pública; en contraste, Holt-Winters demostró ser un modelo capaz de capturar estacionalidades significativas y proyectar tendencias futuras de forma clara y confiable, brindando una herramienta accesible, útil y práctica para la programación operativa.

Se concluye que se identificó un modelo predictivo que se ajusta a los datos históricos del VIH en Medellín y que es viable para la implementación proyección epidemiológica; el modelo Holt-Winters propone una solución metodológica robusta, alineada tanto con los principios de la inteligencia artificial aplicada a los desafíos sociales y clínicos que deben asumir la salud pública en Medellín y otras ciudades latinoamericanas.

La utilidad de los modelos tradicionales en ciertas problemáticas epidemiológicas invita a pensar la aplicación de la inteligencia artificial como una herramienta que, independiente de la sofisticación técnica, diseñada con criterios de simplicidad, transparencia y con sentido social. Los resultados constituyen un aporte significativo para el diseño de modelos predictivos donde se incluyen problemáticas sociales y entornos urbanos vulnerables; abriendo una puerta a nuevas investigaciones que integren el poder analítico de la IA con una mirada ética y de interés en temas de gestión y administración en el diseño estratégico del VIH.

## Referencias

- [[1] Abdool Karim, S. S., Churchyard, G. J., Abdool Karim, Q., & Lawn, S. D. (2019). HIV infection and tuberculosis in South Africa: An urgent need to escalate the public health response. *The Lancet*, \*374\*(9693), 921-933.
- [2] Admassu, Z.; Logie, C. H.; Okumu, M., et al. (2024). HIV vulnerabilities associated with water insecurity, food insecurity, and other COVID-19 impacts among urban refugee youth in Kampala, Uganda: Multi-method findings. *AIDS and Behavior*, \*28\*, 507-523. <https://doi.org/10.1007/s10461-023-04240-8>
- [3] Alcaldía de Medellín. (2016). *Medellín, un ejemplo de atención integral en salud*. <https://www.medellin.gov.co/es/sala-de-prensa/noticias/medellin-un-ejemplo-de-atencion-integral-en-salud/>
- [4] Alcaldía de Medellín. (2023a). \*Plan de Desarrollo 2020-2023: Medellín Futuro – Secretaría de Salud\*. <https://www.medellin.gov.co/es/planes-y-programas/plan-de-desarrollo-medellin-futuro/>
- [5] Alcaldía de Medellín. (2023b). *Presupuesto General Medellín 2023 – Secretaría de Hacienda*. <https://www.medellin.gov.co/es/presupuesto/>
- [6] Anderson, R. M., & May, R. M. (1988). Epidemiological parameters of HIV transmission. *Nature*, \*333\*(6173), 514-519.
- [7] Armstrong, J. S. (2001). *Principles of forecasting*. Springer.
- [8] Auvert, B., et al. (2005). Randomized, controlled intervention trial of male circumcision for reduction of HIV infection risk. *PLoS Medicine*, \*2\*(11), e298.
- [9] Barré-Sinoussi, F., et al. (1983). Isolation of a T-lymphotropic retrovirus from a patient at risk for acquired immune deficiency syndrome (AIDS). *Science*, \*220\*(4599), 868-871.
- [10] Bekker, L. G., et al. (2023). Advancing global health and strengthening the HIV response in the era of the Sustainable Development Goals: The International AIDS Society-Lancet Commission. *The Lancet*, \*401\*(10383), 1318-1336.

- [11] Belén, B. C., & Villarreal Ruiz, J. E. (2024). *Programas de educación sexual y su relación en la prevención de infecciones de transmisión sexual (ITS) en jóvenes del Centro de Salud*. Universidad Técnica de Babahoyo.
- [12] Bergmeir, C., Hyndman, R. J., & Benítez, J. M. (2018). A note on the validity of cross-validation for evaluating time series prediction. *Computational Statistics & Data Analysis*, \*120\*, 70-83. <https://doi.org/10.1016/j.csda.2017.11.003>
- [13] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [14] Blower, S. M., et al. (2000). Predicting the impact of antiretrovirals in resource-poor settings: preventing HIV infections whilst controlling drug resistance. *Current Drug Targets-Infectious Disorders*, \*1\*(1), 15-29.
- [15] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.
- [16] Breiman, L. (2001). Random forests. *Machine Learning*, \*45\*(1), 5-32.
- [17] Cameron, A. C., & Trivedi, P. K. (2013). *Regression Analysis of Count Data*. Cambridge University Press.
- [18] Caruana, R., et al. (2023). Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission. *Journal of Machine Learning Research*, \*24\*(1), 1-45.
- [19] CDC. (1981). Pneumocystis pneumonia - Los Angeles. *MMWR*, \*30\*(21), 1-3.
- [20] Chatfield, C. (2000). Time-series forecasting. *International Statistical Review*, \*68\*(3), 267-276.
- [21] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- [22] Choi, B., et al. (2020). Modeling infectious disease dynamics using deep learning: a review. *IEEE Access*, \*8\*, 104578-104593.
- [23] Chretien, J.-P., et al. (2015). Influenza forecasting in human populations: A scoping review. *PLOS ONE*, \*9\*(4), e94130. <https://doi.org/10.1371/journal.pone.0094130>
- [24] Concejo de Medellín. (2024, noviembre 29). *Concejo aprobó el presupuesto de Medellín para el 2025*. <https://www.concejodemedellin.gov.co/concejo-aprobo-presupuesto-medellin-2025/>
- [25] Constitución Política de Colombia, Artículos 13 y 49. (1991).



- [26] Contreras-Reyes, J. E., & Palma, W. (2013). Statistical modeling of time series using generalized linear models. *Journal of Statistical Planning and Inference*, \*143\*(8), 1316-1326.
- [27] Coopsana. (2023). *Casos de VIH en Medellín*. Medellín, Colombia: Coopsana.
- [28] Corporación Stonewall. (2021). *La respuesta comunitaria: lo positivo del Virus de la Inmunodeficiencia Humana -VIH en las poblaciones transgénero-TRANS y de hombres que tienen sexo con hombres-HSH*. Medellín, Colombia: Corporación Stonewall.
- [29] Daniel Jaramillo Restrepo, V. D. (2023). *Current labor conditions of people with HIV and/or AIDS in Colombia: Analysis based on ILO recommendations and their materialization in the Colombian work environment*. Universidad EAFIT.
- [30] Dejusticia. (2022). *Gasto público municipal en salud y educación en Medellín (2010–2022)*. <https://www.dejusticia.org/gasto-publico-en-medellin-salud-educacion/>
- [31] Eaton, J. W., et al. (2023). Naomi: a new modelling tool for estimating HIV epidemic indicators at the district level in sub-Saharan Africa. *Journal of the International AIDS Society*, \*26\*(3), e26089.
- [32] Efron, B., & Tibshirani, R. J. (1994). *An introduction to the bootstrap*. CRC Press.
- [33] Enríquez Canto, Y., Díaz Gervasi, G., & Menacho Alvirio, L. (2018). Impacto del Programa TARGA en la disminución de casos de sida en el sistema de salud peruano, 1983-2018. *Revista Ranam Salud Pública*.
- [34] Gardner, E. S. (2006). Exponential smoothing: The state of the art—Part II. *International Journal of Forecasting*, \*22\*(4), 637-666.
- [35] García, L. F., et al. (2022). Caracterización molecular y epidemiológica de infecciones recientes por VIH en Medellín. *Biomédica*, \*42\*(3), 456-470.
- [36] García, M. L., & Pérez, R. (2023). *Social Determinants of Health and Their Impact on HIV Outcomes in Latin America*.
- [37] Garnett, G. P. (2002). The geographical and temporal evolution of sexually transmitted disease epidemics. *Sexually Transmitted Infections*, \*78\*(Suppl 1), i14-i19.
- [38] Gobernación de Antioquia. (2012). *Anuario Estadístico de Antioquia*. [https://www.dane.gov.co/files/investigaciones/boletines/anuario\\_estadistico/anuario\\_antioquia\\_2012.pdf](https://www.dane.gov.co/files/investigaciones/boletines/anuario_estadistico/anuario_antioquia_2012.pdf)
- [39] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

- [40] Goodreau, S. M., et al. (2012). Concurrent partnerships, acute infection and HIV epidemic dynamics among young adults in Zimbabwe. *AIDS and Behavior*, \*16\*(2), 312-322.
- [41] Grant, R. M., et al. (2010). Preexposure chemoprophylaxis for HIV prevention in men who have sex with men. *New England Journal of Medicine*, \*363\*(27), 2587-2599.
- [42] Hammer, S. M., et al. (1997). A controlled trial of two nucleoside analogues plus indinavir in persons with human immunodeficiency virus infection and CD4 cell counts of 200 per cubic millimeter or less. *New England Journal of Medicine*, \*337\*(11), 725-733.
- [43] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- [44] Hethcote, H. W. (2000). The mathematics of infectious diseases. *SIAM Review*, \*42\*(4), 599-653.
- [45] Holt, C. C. (2004). *Forecasting seasonals and trends*. INSEAD.
- [46] Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice* (2nd ed.). OTexts.
- [47] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts.
- [48] Instituto Nacional de Salud. (2021). \*Boletín Epidemiológico Nacional: Comportamiento del VIH/SIDA en Colombia, 2015-2020\*.
- [49] Instituto Nacional de Salud. (2021). \*Impacto de la pandemia COVID-19 en la atención del VIH en Colombia. Boletín Epidemiológico Especial\*.
- [50] Instituto Nacional de Salud. (2023). *Informe anual de vigilancia epidemiológica en VIH/SIDA*.
- [51] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning*. Springer.
- [52] Johnson, L. F., et al. (2021). \*The Impact of COVID-19 on HIV Services: A Systematic Review\*.
- [53] Kompella, V., Caprarelli, A., & Pavlovic, V. (2023). Temporal graph networks for deep learning on dynamic graphs. *Neural Information Processing Systems*, \*36\*, 1-15.
- [54] Kompella, V., et al. (2019). Temporal Graph Networks for HIV Transmission Prediction. *Advances in Neural Information Processing Systems (NeurIPS)*.

- [55] Kompella, V., et al. (2022). Temporal graph networks for HIV transmission. *NeurIPS*.
- [56] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, \*521\*(7553), 436-444.
- [57] Leslie, H. H., et al. (2023). Health system measurement: harnessing machine learning for health system improvement. *BMJ Global Health*, \*8\*(2), e011181.
- [58] Ley 100 de 1993. Colombia.
- [59] Ley 1581 de 2012. Colombia.
- [60] Ley 1751 de 2015. Colombia.
- [61] Lopera, M. M. (2019). Factores socioeconómicos y clínicos asociados con infecciones oportunistas en pacientes con HIV afiliados al sistema de salud. *Biomédica*, \*39\*(1), 45-60.
- [62] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, \*30\*, 4765-4774.
- [63] Lundberg, S. M., et al. (2023). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, \*5\*(1), 56-67.
- [64] Mehrabi, N., et al. (2023). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, \*54\*(6), 1-35.
- [65] Metcalf, J., & Crawford, K. (2023). Where are human subjects in Big Data research? The emerging ethics divide. *Big Data & Society*, \*10\*(1), 1-14.
- [66] Méndez, J. C., et al. (2023). Modelos híbridos para predicción del VIH en zonas urbanas de Colombia. *Revista de Salud Pública*, \*25\*(1), 35-49.
- [67] Ministerio de Salud. (2015). *Guía para la reducción de daños y la prevención del VIH y otras ITS asociadas a la inyección de drogas en Colombia*. Colombia: Ministerio de Salud.
- [68] Ministerio de Salud y Protección Social. (2021). *Informe Nacional de Respuesta al VIH/Sida*.
- [69] Ministerio de Salud y Protección Social. (2022). *\*Plan Decenal de Salud Pública 2022-2031\**.
- [70] Navarrete Bellot, L. (2020). *Aplicación de métodos de aprendizaje automático para el estudio del análisis de supervivencia en pacientes infectados por el VIH*. España: Universidad Oberta de Catalunya.
- [71] Nguyen, D., et al. (2020). Machine learning approaches in HIV research. *Computational and Structural Biotechnology Journal*, \*18\*, 2874-2882.

- [72] Organización de las Naciones Unidas (ONU). (s.f.). *Objetivos de Desarrollo Sostenible (ODS). ODS 3: Salud y Bienestar*.
- [73] Organización Mundial de la Salud. (2023). *HIV/AIDS: Data and statistics*.
- [74] Organización Panamericana de la Salud (OPS). (2022). *HIV in Latin America: Situation and Response*.
- [75] Ortiz, M., Prada, G., & Rodríguez, J. (2021). Migración venezolana y salud sexual: Barreras de acceso en poblaciones vulnerables en Colombia. *Revista Colombiana de Salud Pública*, \*23\*(2), 45-62.
- [76] Palella, F. J., et al. (1998). Declining morbidity and mortality among patients with advanced human immunodeficiency virus infection. *New England Journal of Medicine*, \*338\*(13), 853-860.
- [77] Parker, R., Aggleton, P., & Pérez-Brumer, A. (2020). The trouble with 'categories': Rethinking men who have sex with men, transgender and their equivalents in HIV prevention and health promotion. *Global Public Health*, \*15\*(7), 814-823.
- [78] Poon, A. F., et al. (2023). The impact of clinical, demographic and risk factors on rates of HIV transmission: a population-based phylogenetic analysis. *The Lancet HIV*, \*10\*(3), e158-e167.
- [79] Powers, K. A., et al. (2015). Machine learning to predict HIV incidence in South Africa. *JAIDS*.
- [80] Profamilia. (2021). *Encuesta Nacional de Demografía y Salud: Salud sexual y reproductiva en Colombia*.
- [81] Resolución 8430 de 1993. Colombia.
- [82] Restrepo, G. C. (2009). Inequities in health related to HIV--AIDS. *Perspectivas en Nutrición Humana*.
- [83] Rieke, N., et al. (2023). The future of digital health with federated learning. *NPJ Digital Medicine*, \*6\*(1), 1-7.
- [84] Rodríguez, A., & Fernández, E. (2023). *The Role of Predictive Models in HIV Epidemic Control: A Case Study of Urban Centers in Colombia*.
- [85] Secretaría de Salud de Medellín. (2022). *Informe anual de vigilancia epidemiológica en VIH/SIDA*. Alcaldía de Medellín.
- [86] Secretaría de Salud de Medellín. (2023). *Análisis de Situación de Salud con el Modelo de los Determinantes Sociales*.

- [87] Semana.com. (2023). Alerta en Medellín: se dispararon los contagios de VIH-Sida, especialmente entre los jóvenes. El turismo sexual es una de las razones. Hay cinco nuevos casos diarios. *Semana*.
- [88] Shmueli, G. (2010). To explain or to predict? *Statistical Science*, \*25\*(3), 289-310.
- [89] Shumway, R. H., & Stoffer, D. S. (2017). *Time series analysis and its applications: With R examples* (4th ed.). Springer.
- [90] Smith, J. A., & Jones, B. C. (2022). *Machine Learning Applications in Public Health: A Review of Recent Advances*.
- [91] Susana Monge, & Pérez Molina, J. (2016). HIV infection and immigration. *Enfermedades Infecciosas y Microbiología Clínica*.
- [92] Taylor, J. W. (2003). Short-term electricity demand forecasting using double seasonal exponential smoothing. *Journal of Forecasting*, \*22\*(6-7), 425-436.
- [93] Torgo, L., et al. (2013). SMOTE for regression. *Data Mining and Knowledge Discovery*, \*27\*(3), 371-408.
- [94] UNAIDS. (2022). *The impact of social and economic factors on HIV transmission. UNAIDS Report*, Geneva.
- [95] UNAIDS. (2023). *The path that ends AIDS: 2023 UNAIDS Global AIDS Update*. Joint United Nations Programme on HIV/AIDS.
- [96] Volz, E. M., et al. (2023). HIV-1 transmission during early infection in men who have sex with men: a phylodynamic analysis. *LoS Medicine*, \*20\*(3), e1004188.
- [97] WHO. (2021). *Ethics and Governance of Artificial Intelligence for Health. WHO Guidelines*.
- [98] Winters, P. R. (1960). Forecasting sales by exponentially weighted moving averages. *Management Science*, \*6\*(3), 324-342.
- [99] World Health Organization. (2022). *Consolidated Guidelines on HIV Prevention, Testing, Treatment, Service Delivery, and Monitoring: Recommendations for a Public Health Approach*.
- [100] Young, S. D., Yu, W., & Wang, W. (2023). Toward automating HIV identification: machine learning for rapid detection of HIV-related risk behaviors on social media. *Journal of Medical Internet Research*, \*25\*(1), e41472.
- [101] Zhang, X., et al. (2018). Deep Learning for HIV Incidence Forecasting. *Journal of Medical Internet Research*, \*20\*(5), e10258.

- [102] Zhang, X., et al. (2021). Deep Learning for HIV Incidence Forecasting in Urban Settings. *Lancet Digital Health*, \*3\*(6), e398-e406.
- [103] Zhang, X., et al. (2021). Deep learning for HIV forecasting. *Nature Digital Medicine*.
- [104] Zhang, X., Wang, J., Zhang, K., & Sun, J. (2023). Deep learning for epidemiological time series forecasting: A survey. *ACM Computing Surveys*, \*56\*(3), 1-37.